

인공지능

CHAP 13 - 신경망 2 (MLP)



Contents

신경망 2 (MLP)

- 다층 퍼셉트론

- 역전파 학습 알고리즘

- 역전파 알고리즘 유도

- 구글의 플레이그라운드를 이용한 실습

- 넘파이를 이용하여 MLP 구현

- 구글의 텐서플로우

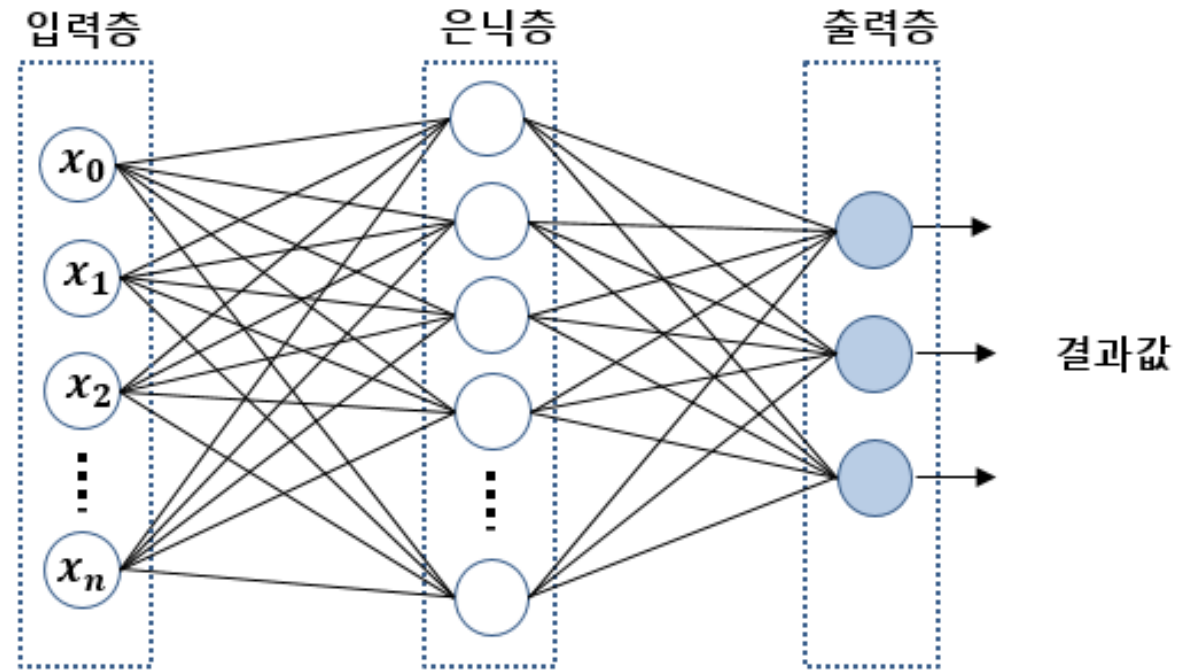


01

다층 퍼셉트론



다층 퍼셉트론(MLP : Multilayer Perceptron)



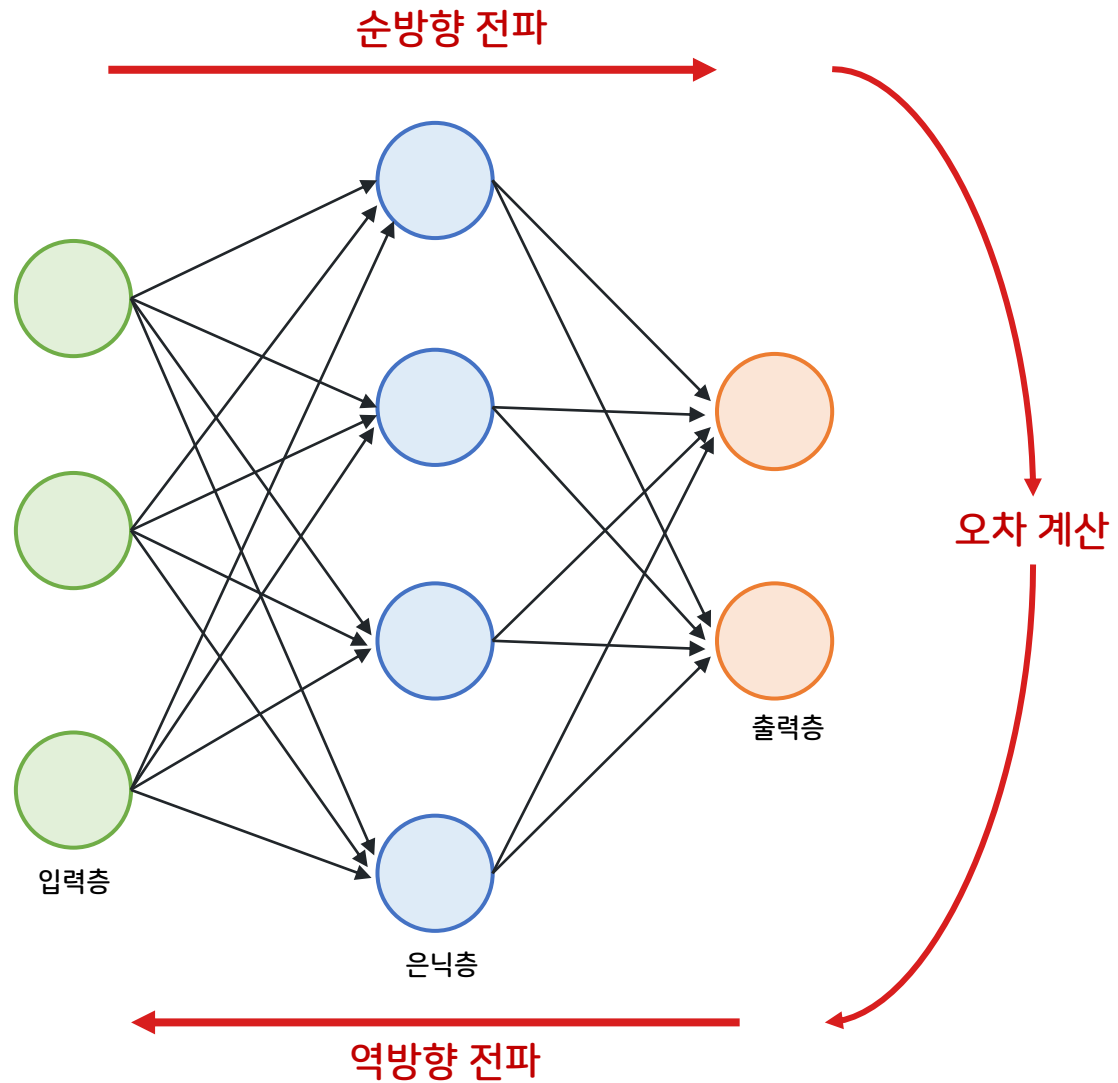
<https://blog.naver.com/PostView.nhn?blogId=samsjang&logNo=221030487369&parentCategoryNo=&categoryNo=87&viewDate=&isShowPopularPosts=true&from=search>

입력층과 출력층 사이에 은닉층(Hidden Layer)을 가지고 있는 신경망

단층 퍼셉트론으로 학습할 수 없었던 XOR 문제도 학습 가능




다층 퍼셉트론 학습 알고리즘 : 역전파 알고리즘



입력이 주어지면 순방향으로 계산하여 출력을 계산한 후, 실제 출력과 우리가 원하는 출력 간의 오차를 계산하여 이 오차를 역방향으로 전파하면서 오차를 줄이는 방향으로 가중치를 변경함




Sigmoid 함수




$$f(x) = \frac{1}{1 + e^{-x}}$$

TanH 함수



$$\tanh(x) = \frac{2}{1 + e^{-2x}} - 1$$

ReLU 함수



$$f(x) = \begin{cases} 0 & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$$

선형함수를 사용하면 은닉층을 아무리 많이 두어도 성능이 전혀 향상되지 않음

따라서 다층 퍼셉트론의 성능을 개선하기 위해서는 반드시 **비선형 함수**를 사용하여야 함



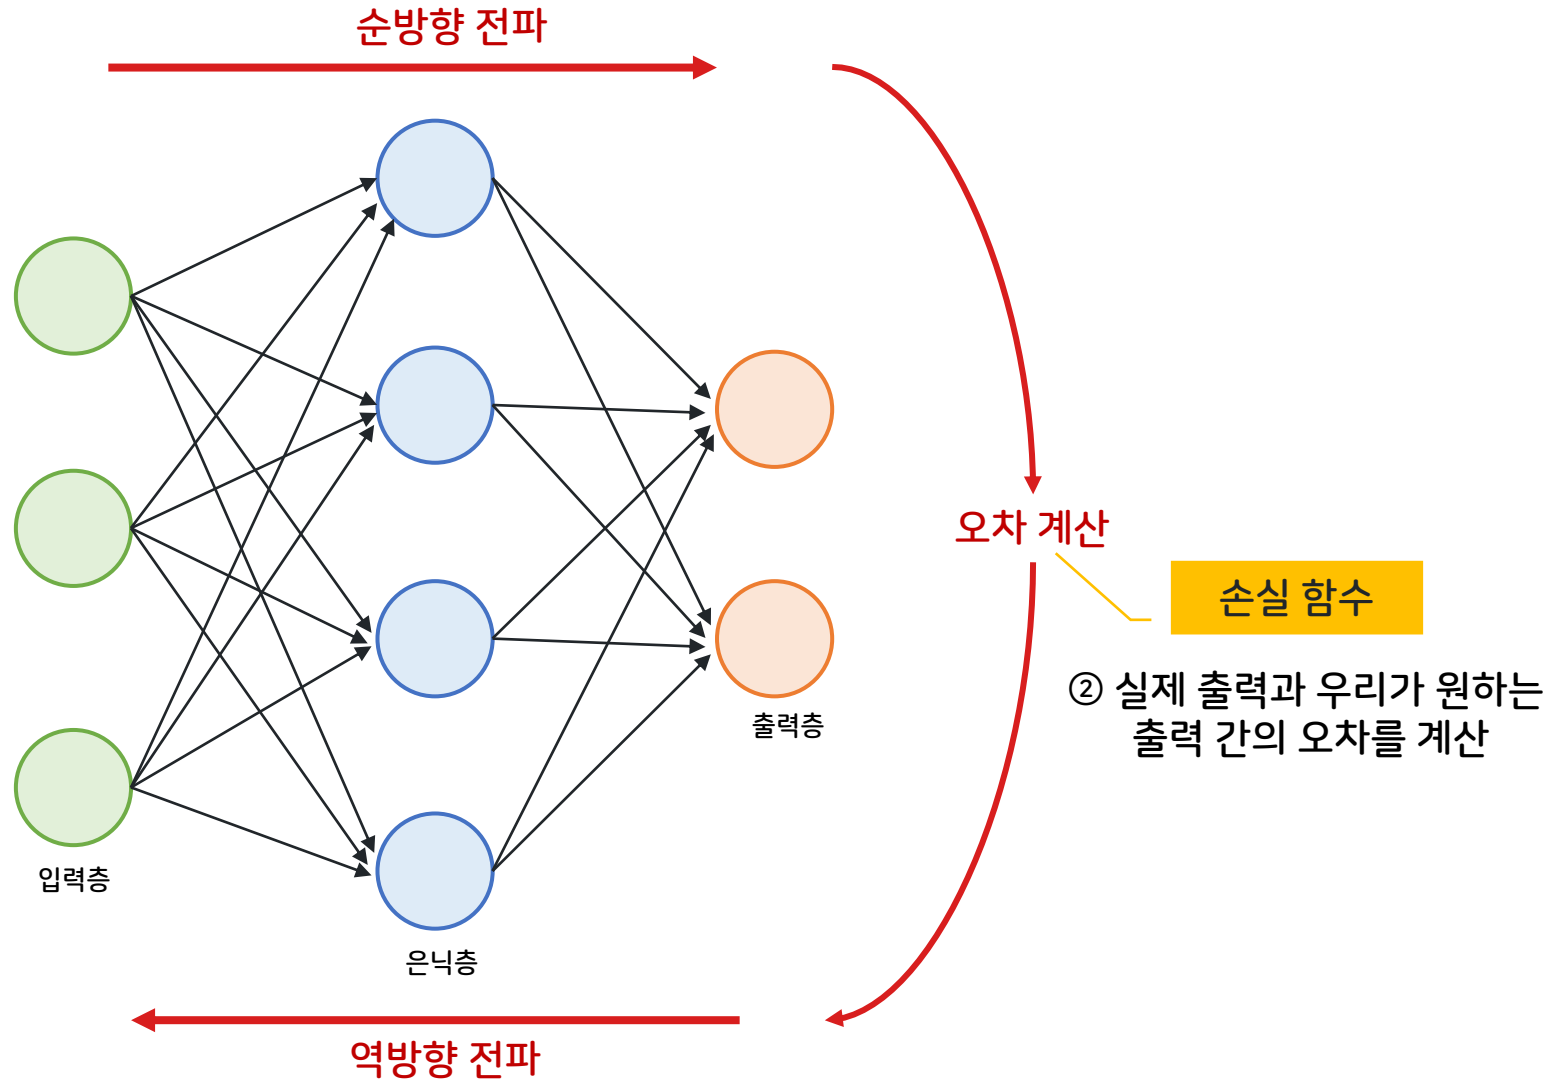
02

역전파 학습 알고리즘



역전파 학습 알고리즘 : 손실 함수란?

① 입력이 주어지면 순방향으로 계산하여 출력을 계산한 후



③ 오차를 역방향으로 전파하면서 오차를 줄이는 방향으로 가중치를 변경함

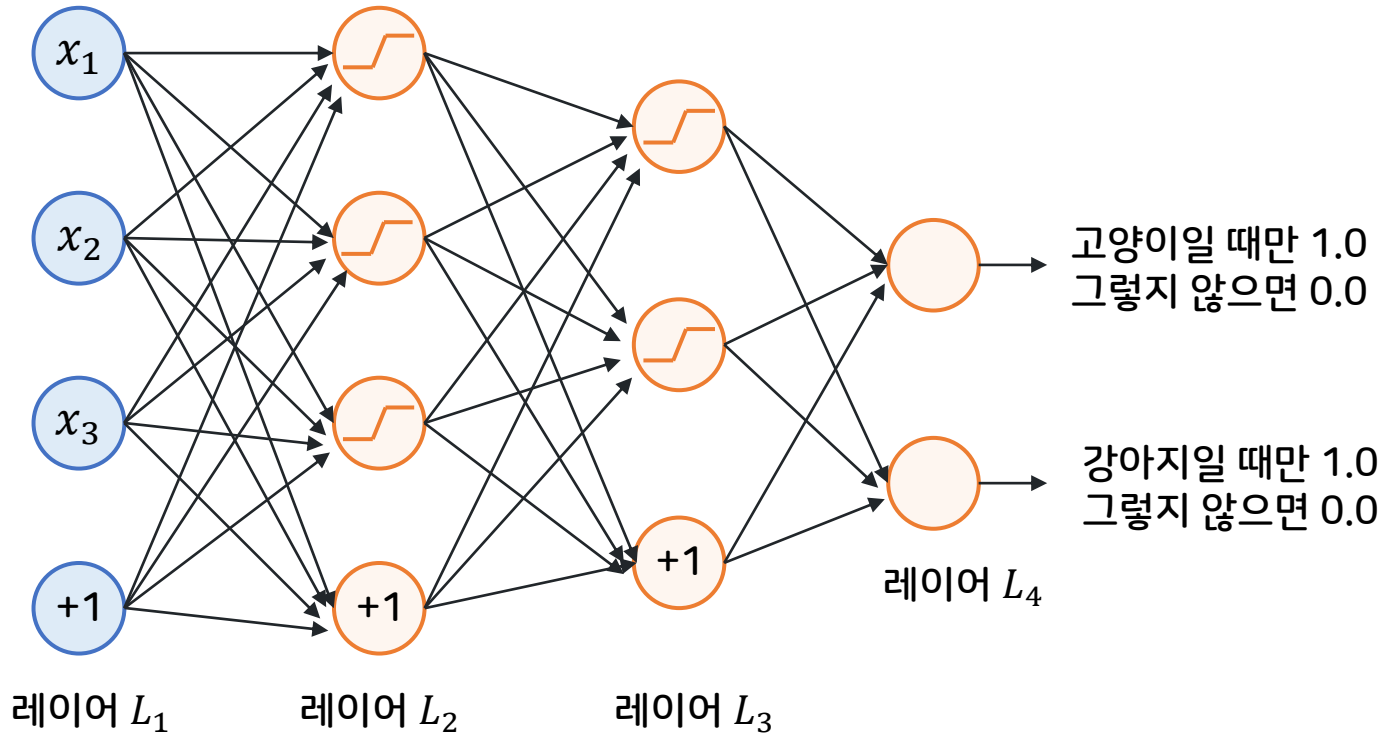


역전파 학습 알고리즘 : 손실 함수란?

입력 이미지



OR



만약
입력 이미지가 고양이라면
올바른 출력은 (1,0)

만약
입력 이미지가 강아지라면
올바른 출력은 (0,1)

1000장의 이미지를 가지고 학습을 수행 ▶ **정답** 고양이 사진 출력 (1,0) ▶ **오답** 이어서 강아지 사진 출력(1,0)

강아지 이미지에 대한 올바른 출력은 **목표 출력값** (0,1) 실제 출력은 (1,0) ▶ 오차는 $(0-1)^2 + (1-0)^2 = 2.0$
실제 출력값



역전파 학습 알고리즘 : 손실 함수

$$E(w) = \frac{1}{2} \sum_i (t_i - o_i)^2$$

w : 가중치, i : 출력 노드의 번호, t : 훈련 샘플의 목표 출력값, o : 실제 출력값




역전파 알고리즘은 손실 함수 값을 줄이는 문제를 최적화 문제로 접근

$E(w)$ 를 최소로 만드는 가중치 w 를 찾기



만약 손실 함수 값이 0이 되었다면 입력을 완벽하게 분류한 것





그래디언트는 접선의 기울기로 이해
해도 됩니다. 접선의 기울기가 양수
이면 반대로 w 를 감소시킵니다.




그림 13-7 경사 하강법



역전파 학습 알고리즘 : 경사하강법

$$E(w) = \frac{1}{2} \sum_i (t_i - o_i)^2$$

$E(w)$ 를 최소로 만드는 가중치 w 를 찾기



경사하강법을 이용한 가중치 변경

$$w(t+1) = w(t) - \eta \frac{\partial E}{\partial w}$$

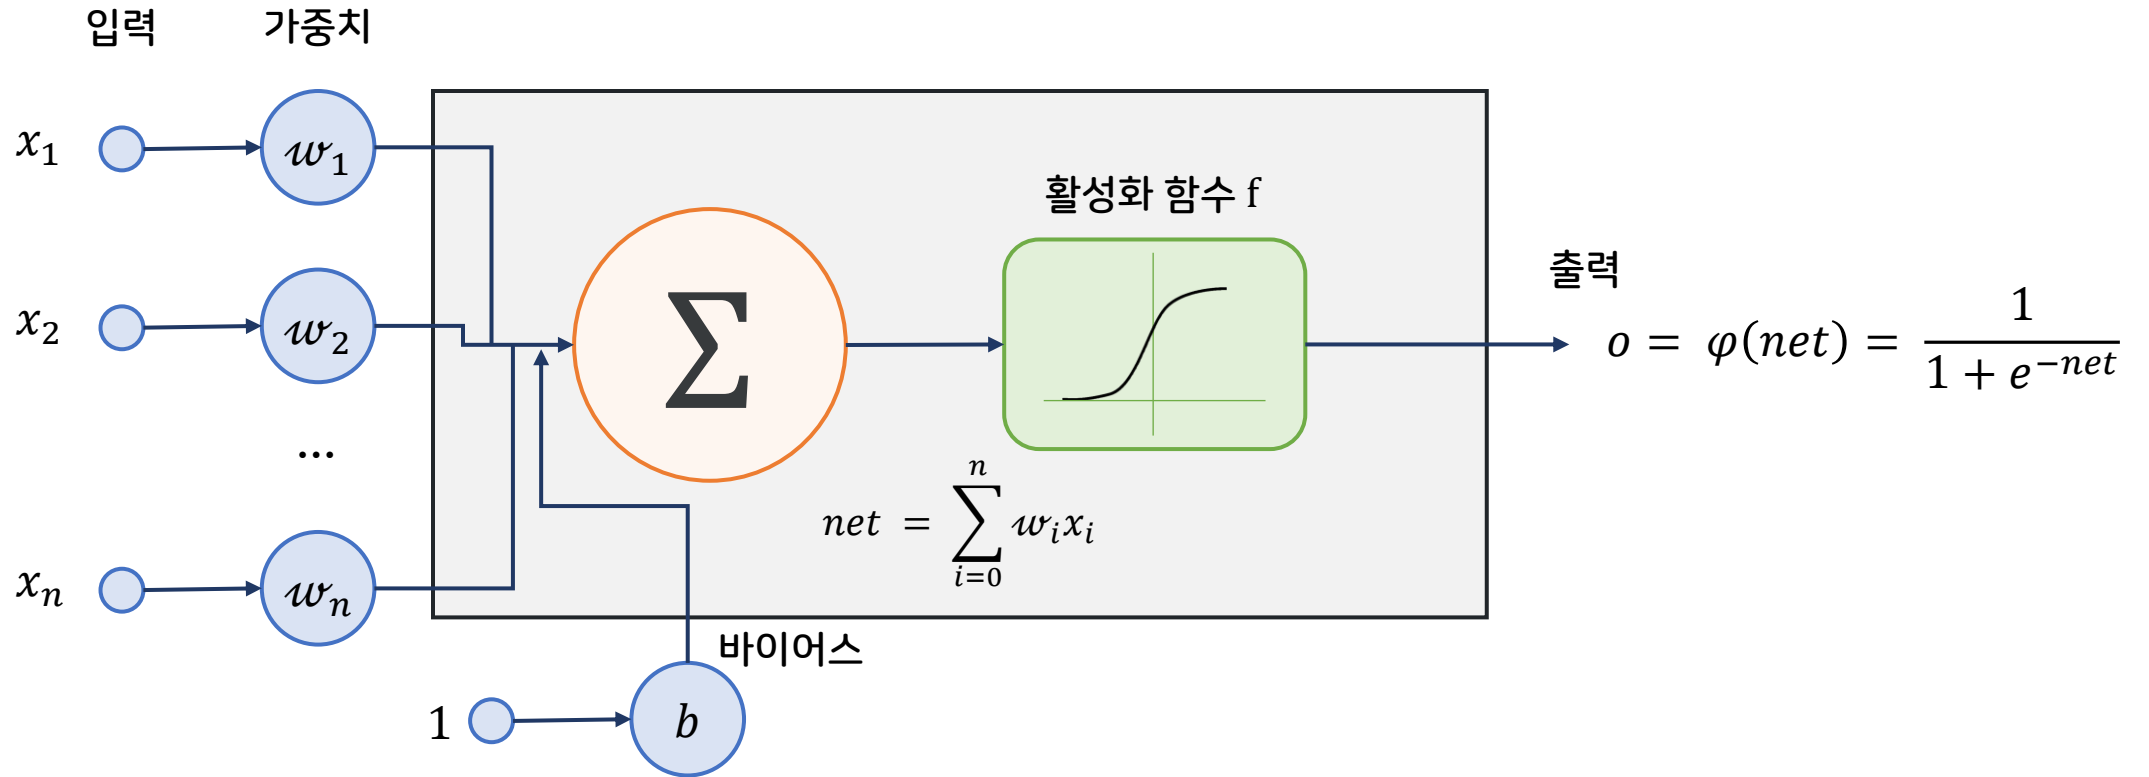
$w(t)$: 현재의 가중치, η : 학습률(0~1 사이 값), $w(t+1)$: 변경 후 가중치



03

역전파 알고리즘의 유도





활성화 함수

Sigmoid 함수

$$\varphi(z) = \frac{1}{1 + e^{-z}}$$

손실 함수

$$E = \frac{1}{2} \sum_{j=1}^m (t_j - o_j)^2$$

m : 출력 노드 개수, t : 목표 출력, o : 실제 출력

편미분 값

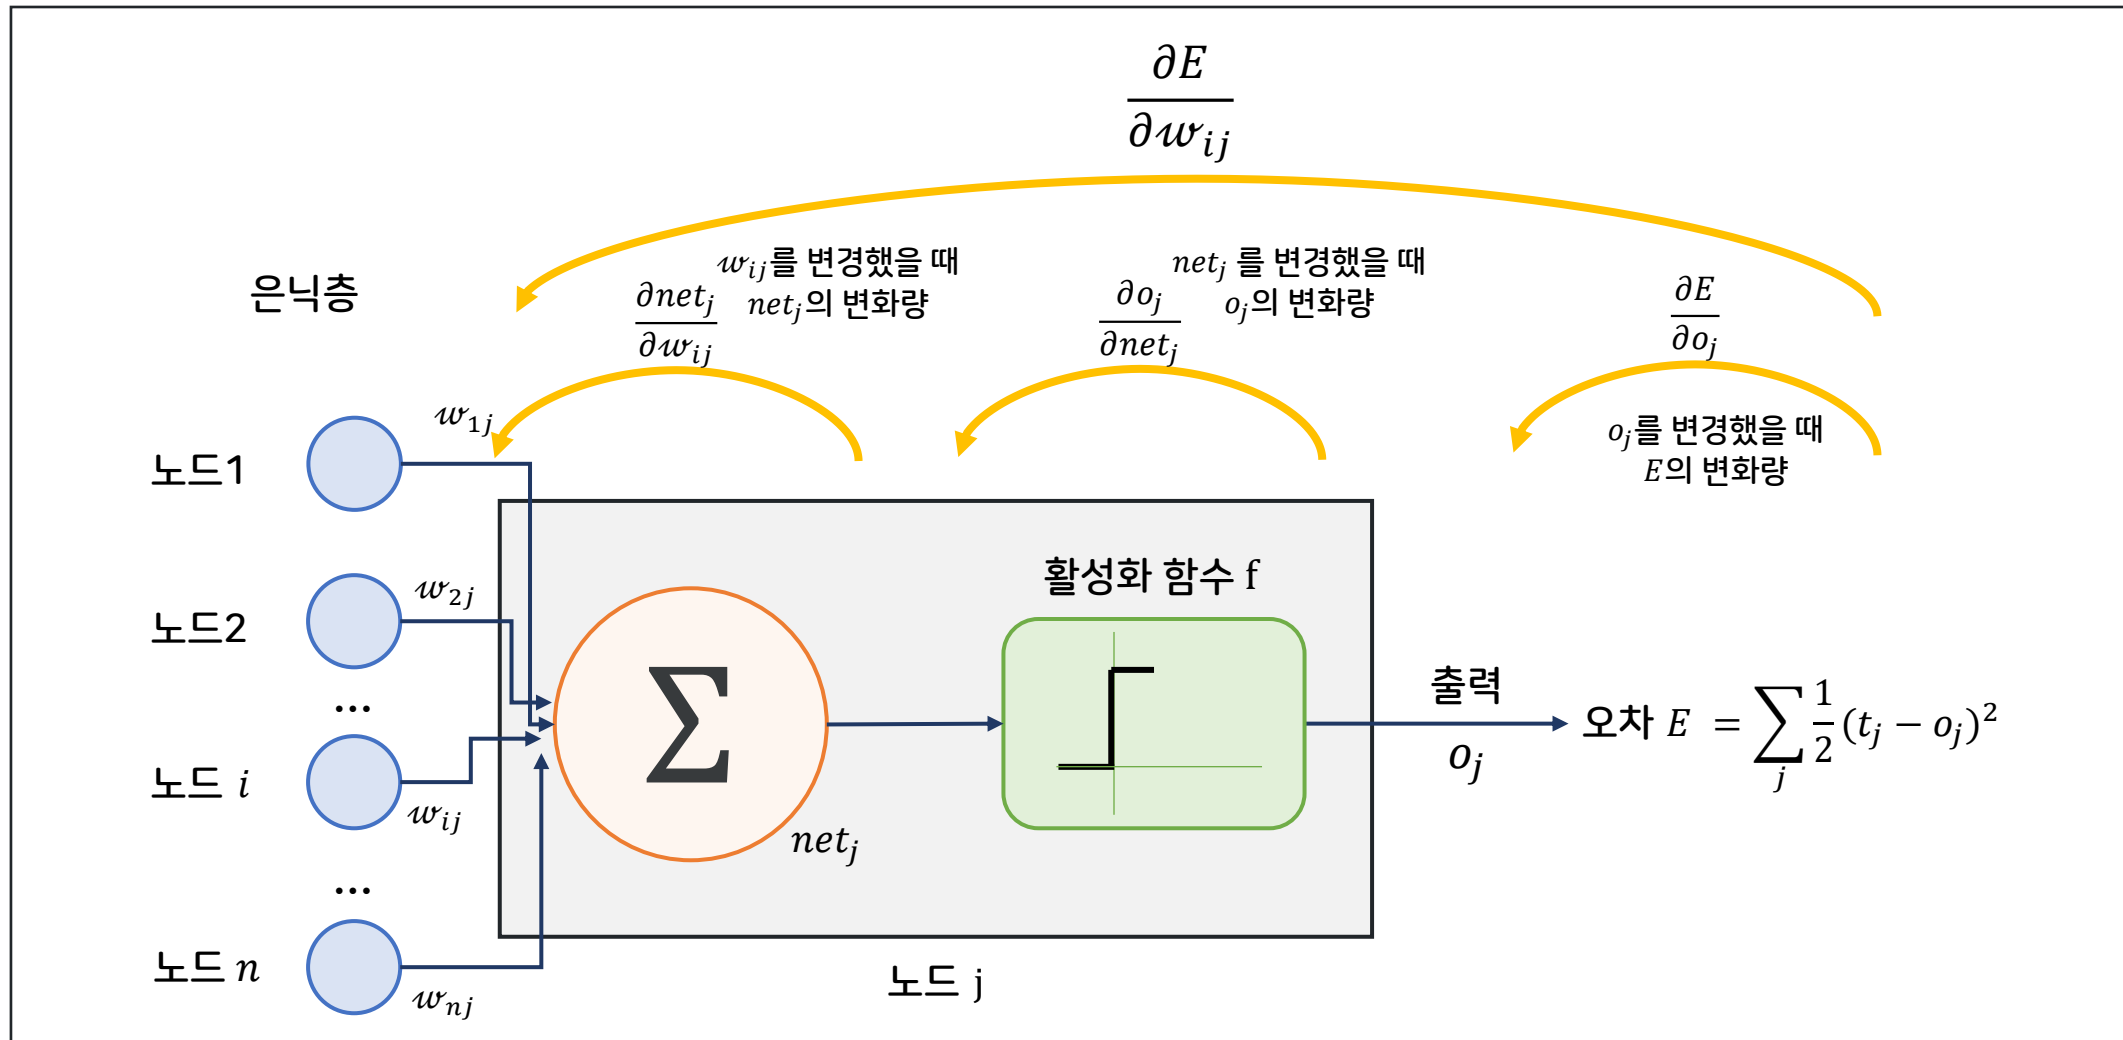
$$\frac{\partial E}{\partial w_{ij}}$$

w_{ij} : 노드 i 와 노드 j 를 연결하는 선의 가중치
 w_{ij} 가 변했을 때 손실함수 E 가 얼마나 변하는가?

체인룰 사용

$$\frac{\partial E}{\partial w_{ij}} \xrightarrow{\text{체인룰}} \frac{\partial E}{\partial w_{ij}} = \frac{\partial E}{\partial o_j} \frac{\partial o_j}{\partial net_j} \frac{\partial net_j}{\partial w_{ij}}$$

노드 j가 출력층에 있는 노드

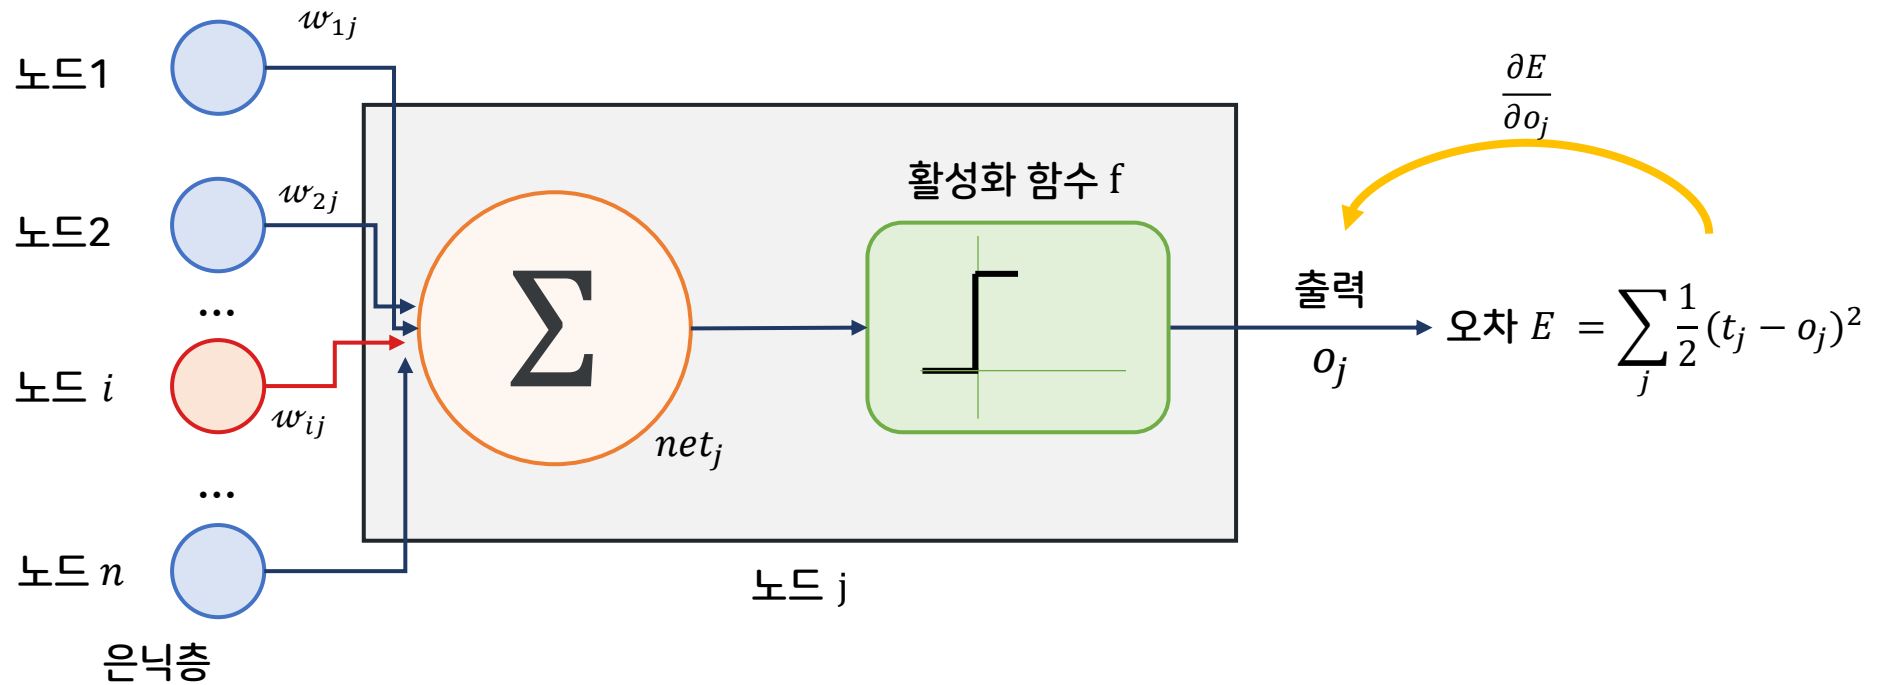


출력 노드의 경우

$$\frac{\partial E}{\partial w_{ij}} = \frac{\partial E}{\partial o_j} \frac{\partial o_j}{\partial net_j} \frac{\partial net_j}{\partial w_{ij}}$$

① ② ③

① 노드의 출력값 변화에 따른 오차의 변화율

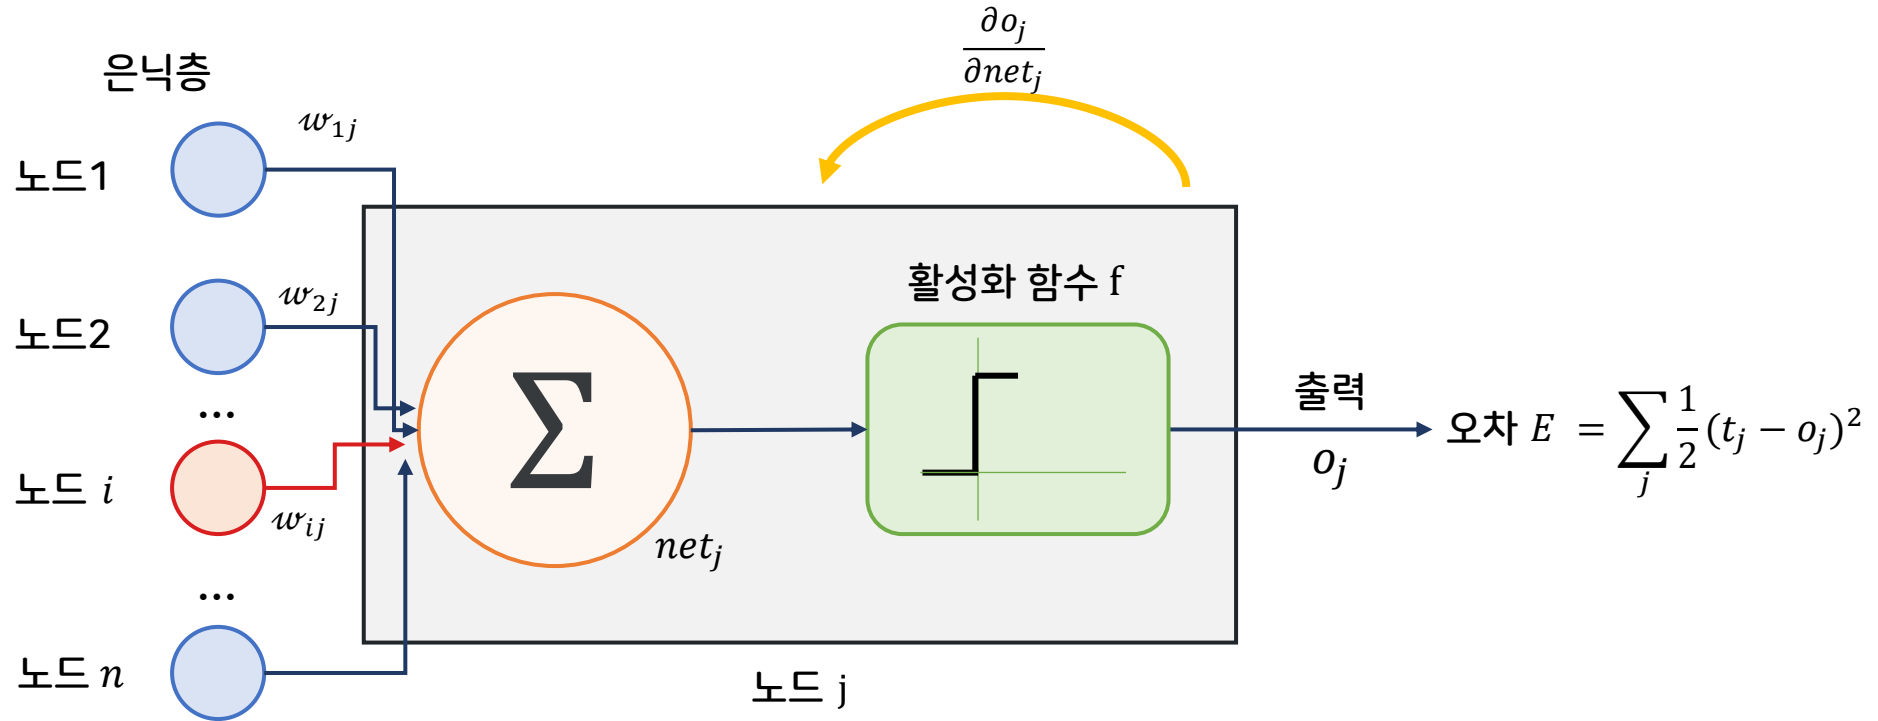


j 번째 노드가 출력 노드라면, $\frac{\partial E}{\partial o_j} = \frac{\partial}{\partial o_j} \sum_k \frac{1}{2} (t_k - o_k)^2 = o_j - t_j$



$$\frac{\partial E}{\partial w_{ij}} = \overset{\textcircled{1}}{\frac{\partial E}{\partial o_j}} \overset{\textcircled{2}}{\frac{\partial o_j}{\partial net_j}} \overset{\textcircled{3}}{\frac{\partial net_j}{\partial w_{ij}}}$$

② 입력합의 변화에 따른 노드 j의 출력 변화율

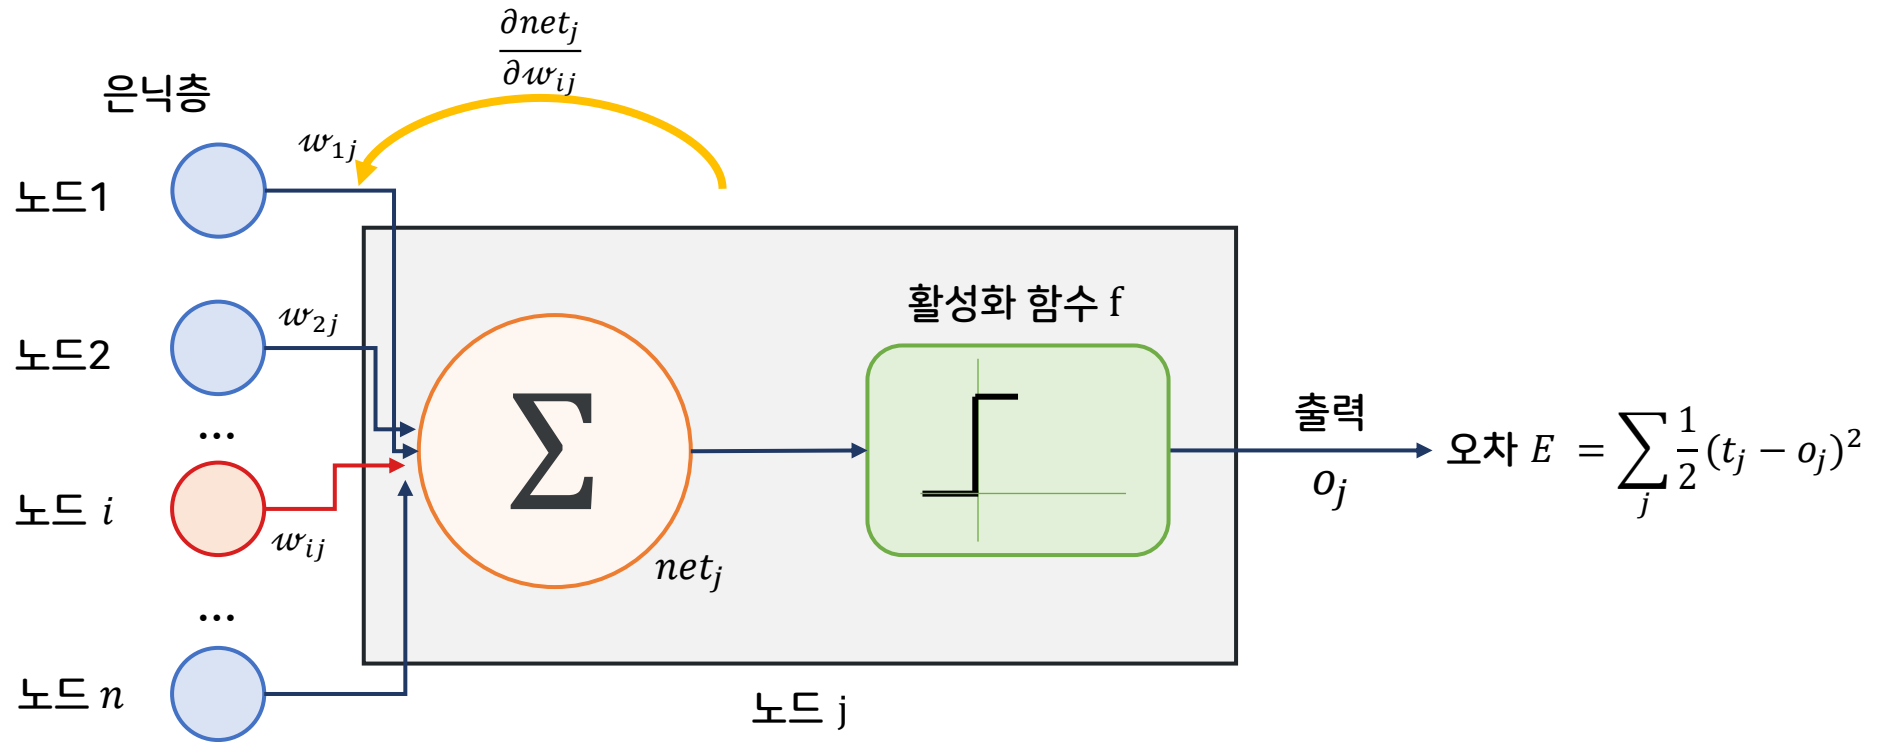


$$\frac{\partial o_j}{\partial net_j} = \frac{\partial \phi(net_j)}{\partial net_j} = \phi(net_j) (1 - \phi(net_j))$$



$$\frac{\partial E}{\partial w_{ij}} = \overset{\textcircled{1}}{\frac{\partial E}{\partial o_j}} \overset{\textcircled{2}}{\frac{\partial o_j}{\partial net_j}} \overset{\textcircled{3}}{\frac{\partial net_j}{\partial w_{ij}}}$$

③ 가중치의 변화에 따른 net_j 의 변화율



$$\frac{\partial net_j}{\partial w_{ij}} = \frac{\partial}{\partial w_{ij}} \left(\sum_{k=0}^n w_{kj} o_k \right) = \frac{\partial}{\partial w_{ij}} w_{ij} o_j = o_i$$



노드 j 가 출력층에 있는 노드

$$\frac{\partial E}{\partial w_{ij}} = \frac{\partial E}{\partial o_j} \frac{\partial o_j}{\partial net_j} \frac{\partial net_j}{\partial w_{ij}} = (o_j - t_j) \varphi(net_j) (1 - \varphi(net_j)) o_i$$

총정리

$$\delta_j = \frac{\partial E}{\partial o_j} \frac{\partial o_j}{\partial net_j}$$

δ_j 는 신경망 계층에 따라 다음과 같이 구분하여서 계산

$$\delta_j = \begin{cases} \varphi'(net_j)(o_j - t_j) & \leftarrow j \text{가 출력 계층이면} \\ \left(\sum_k w_{jk} \delta_k \right) \varphi'(net_j) & \leftarrow j \text{가 은닉 계층이면} \end{cases}$$

가중치의 변화량 Δw_{ij} 은 다음식으로 계산

$$\Delta w_{ij} = -\eta \frac{\partial E}{\partial w_{ij}} - \eta o_i \delta_j$$



04

구글의 플레이그라운드 실습

Tinker With a **Neural Network** Right Here in Your Browser.
Don't Worry, You Can't Break It. We Promise.

학습 시작 버튼



Epoch
000,000

Learning rate
0.03

Activation
Tanh

Regularization
None

Regularization rate
0

Problem type
Classification

입력 데이터 세트

DATA
Which dataset do you want to use?

Ratio of training to test data: 50%

Noise: 0

Batch size: 10

REGENERATE

FEATURES
Which properties do you want to feed in?

X_1
 X_2
 X_1^2
 X_2^2
 X_1X_2
 $\sin(X_1)$
 $\sin(X_2)$

입력층

+ - 2 HIDDEN LAYERS

+ -
4 neurons


은닉층

+ -
2 neurons

출력층

OUTPUT

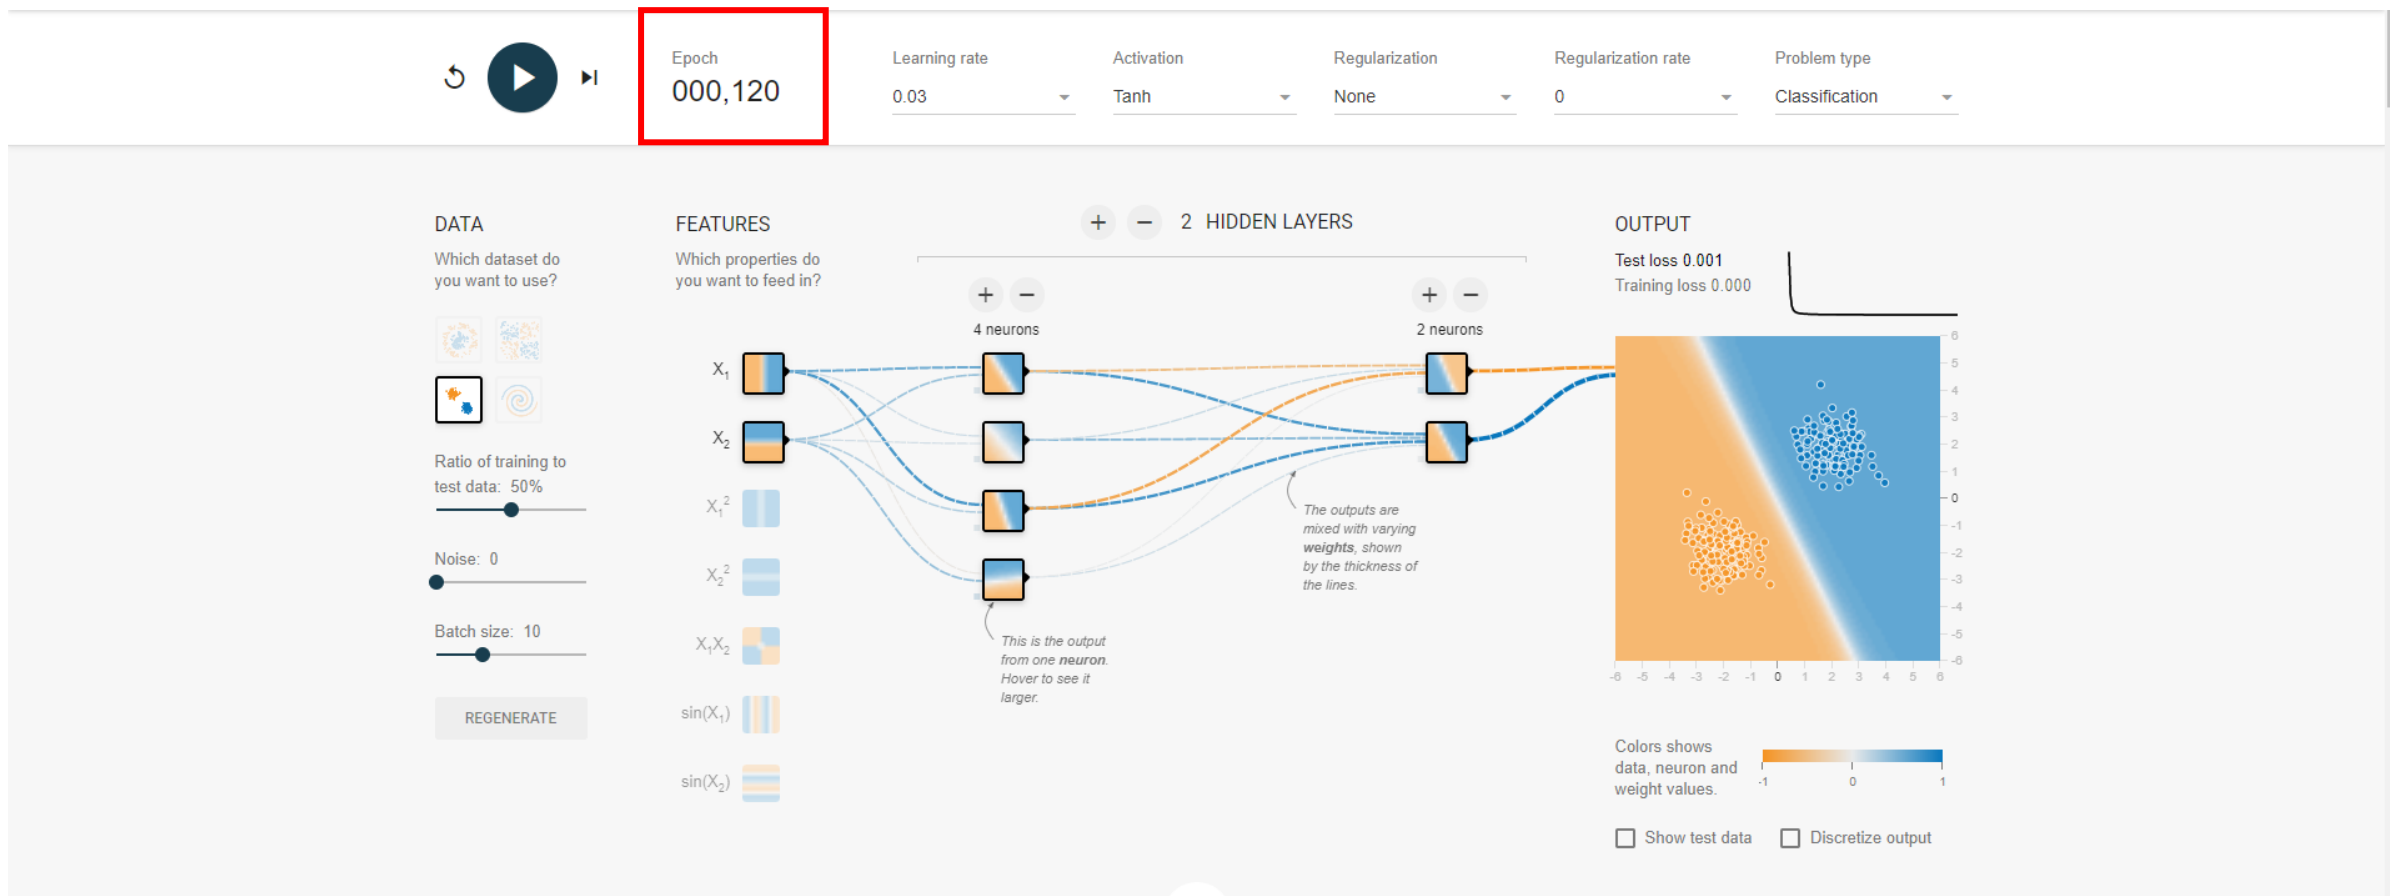
Test loss 0.519
Training loss 0.513



Colors shows data, neuron and weight values.

☐ Show test data ☐ Discretize output

에포크

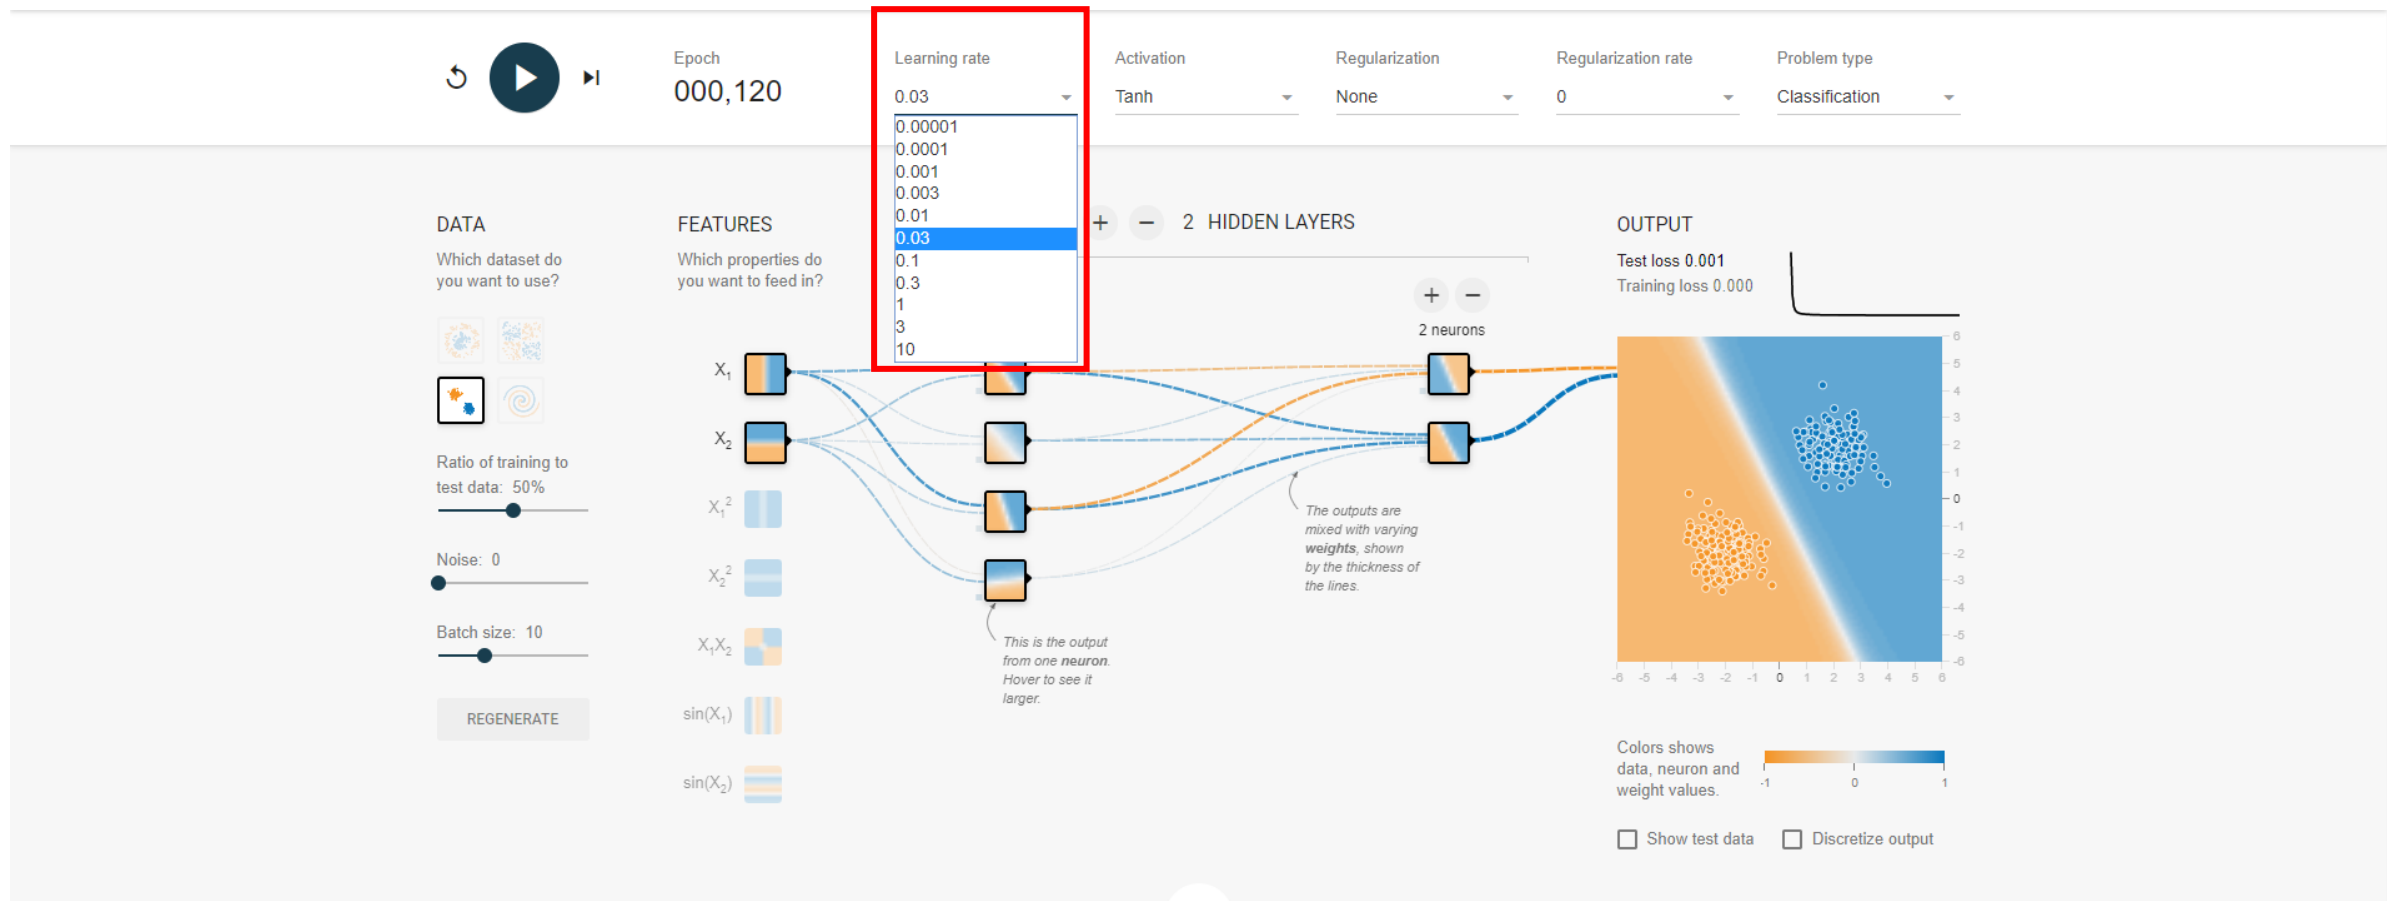


에포크

준비된 학습 예제를 한번 반복

학습 예제 세트에 대해 학습을 한 번 실시할 때마다 에포크 수 증가

학습률

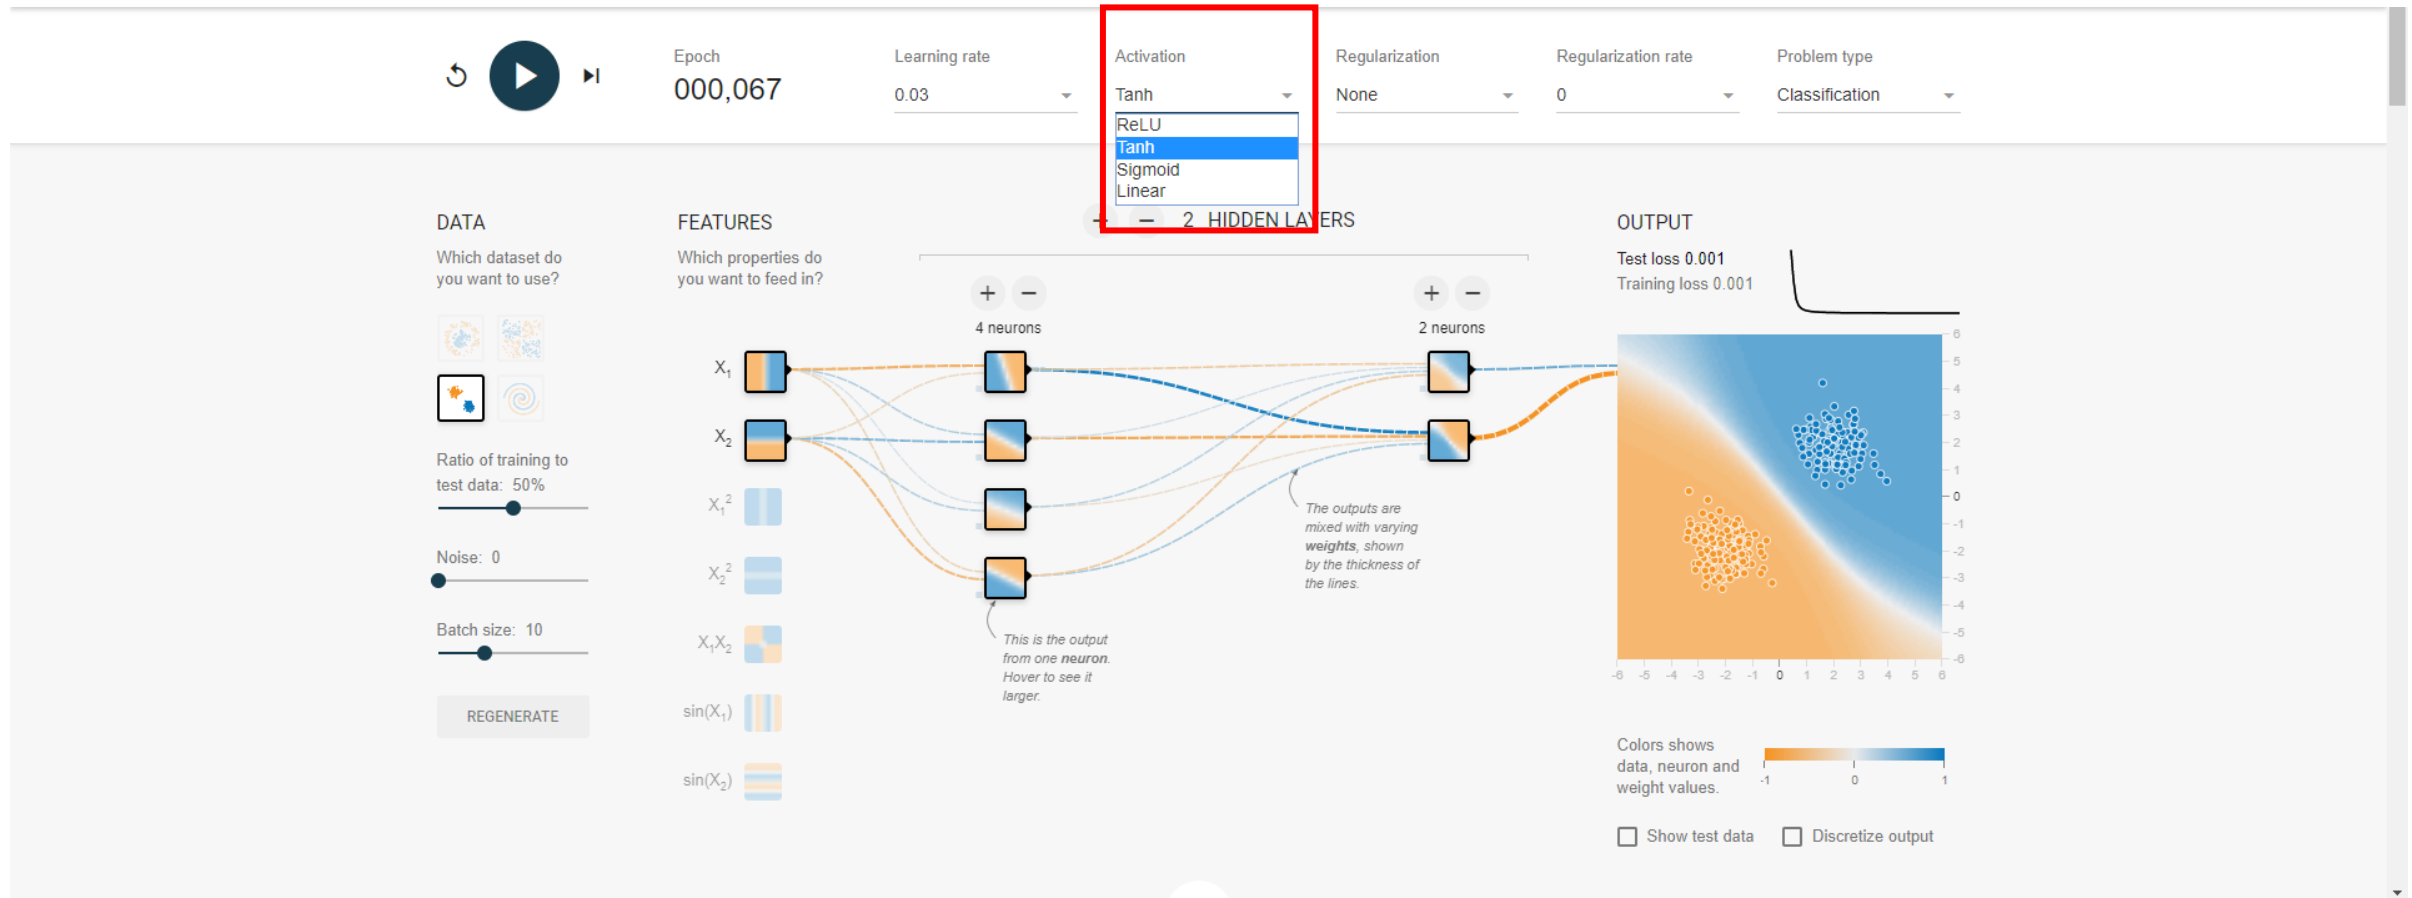


학습률

학습 속도 결정

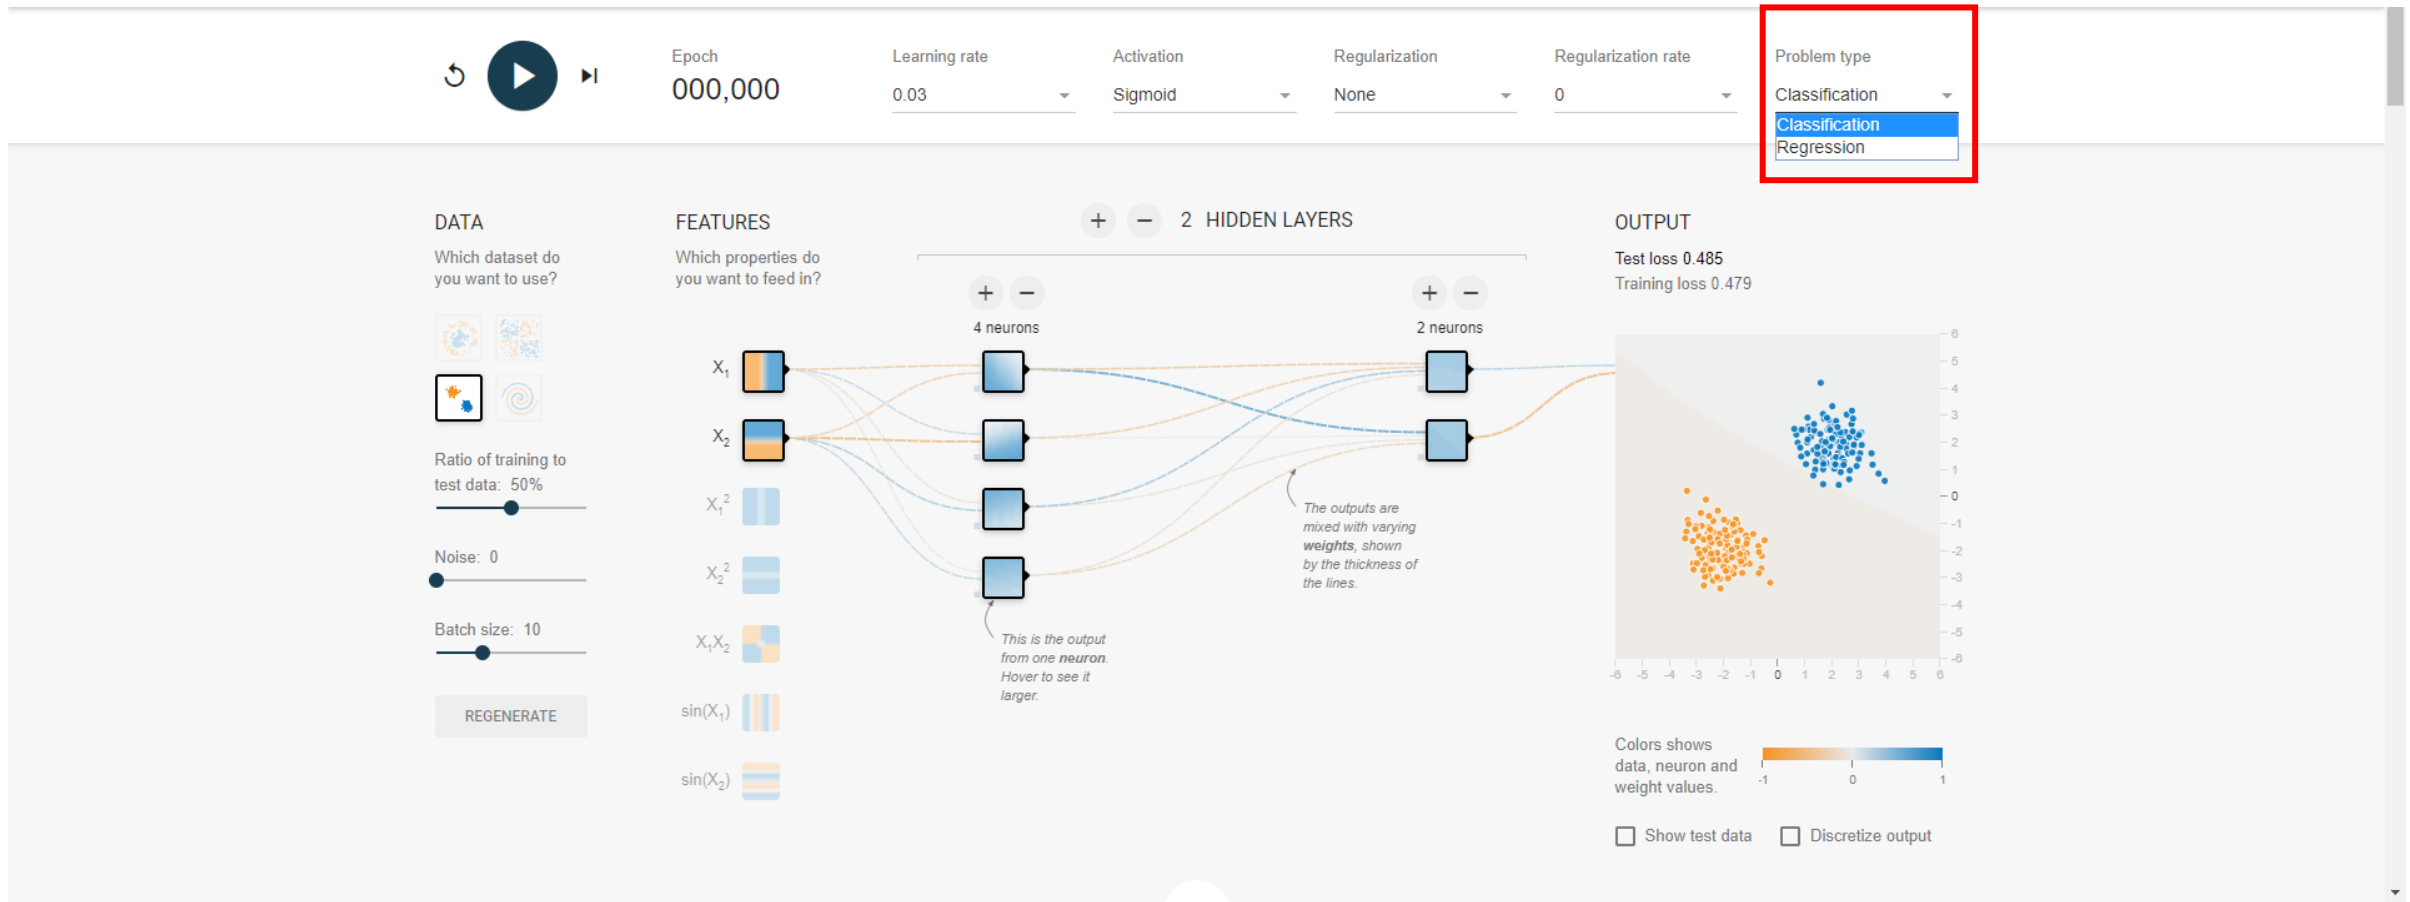
숫자가 커질수록 학습속도 ↑

활성화 함수



활성화 함수

활성화 함수마다 학습되는 모양이 조금씩 상이함

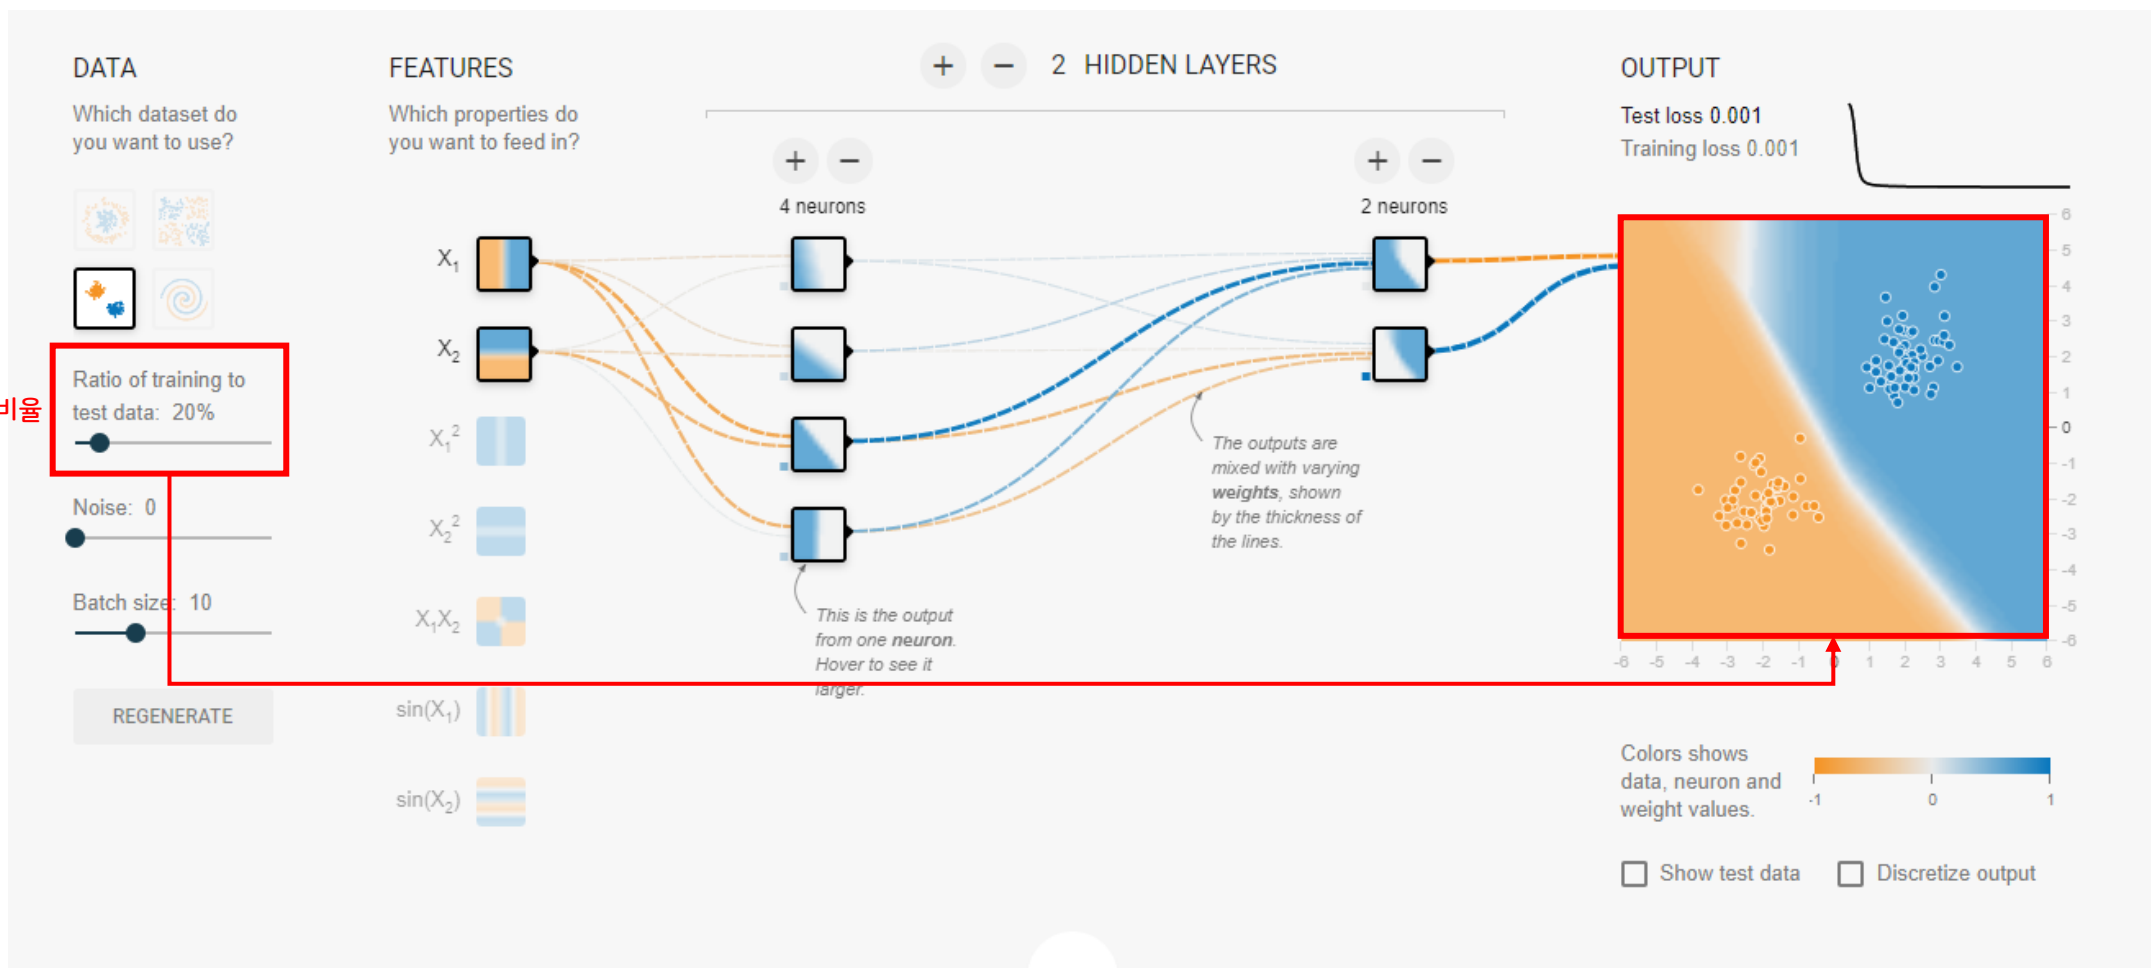


문제 유형

Classification : 분류, Regression : 회귀

분류는 입력데이터 유형 4개, 회귀는 2개

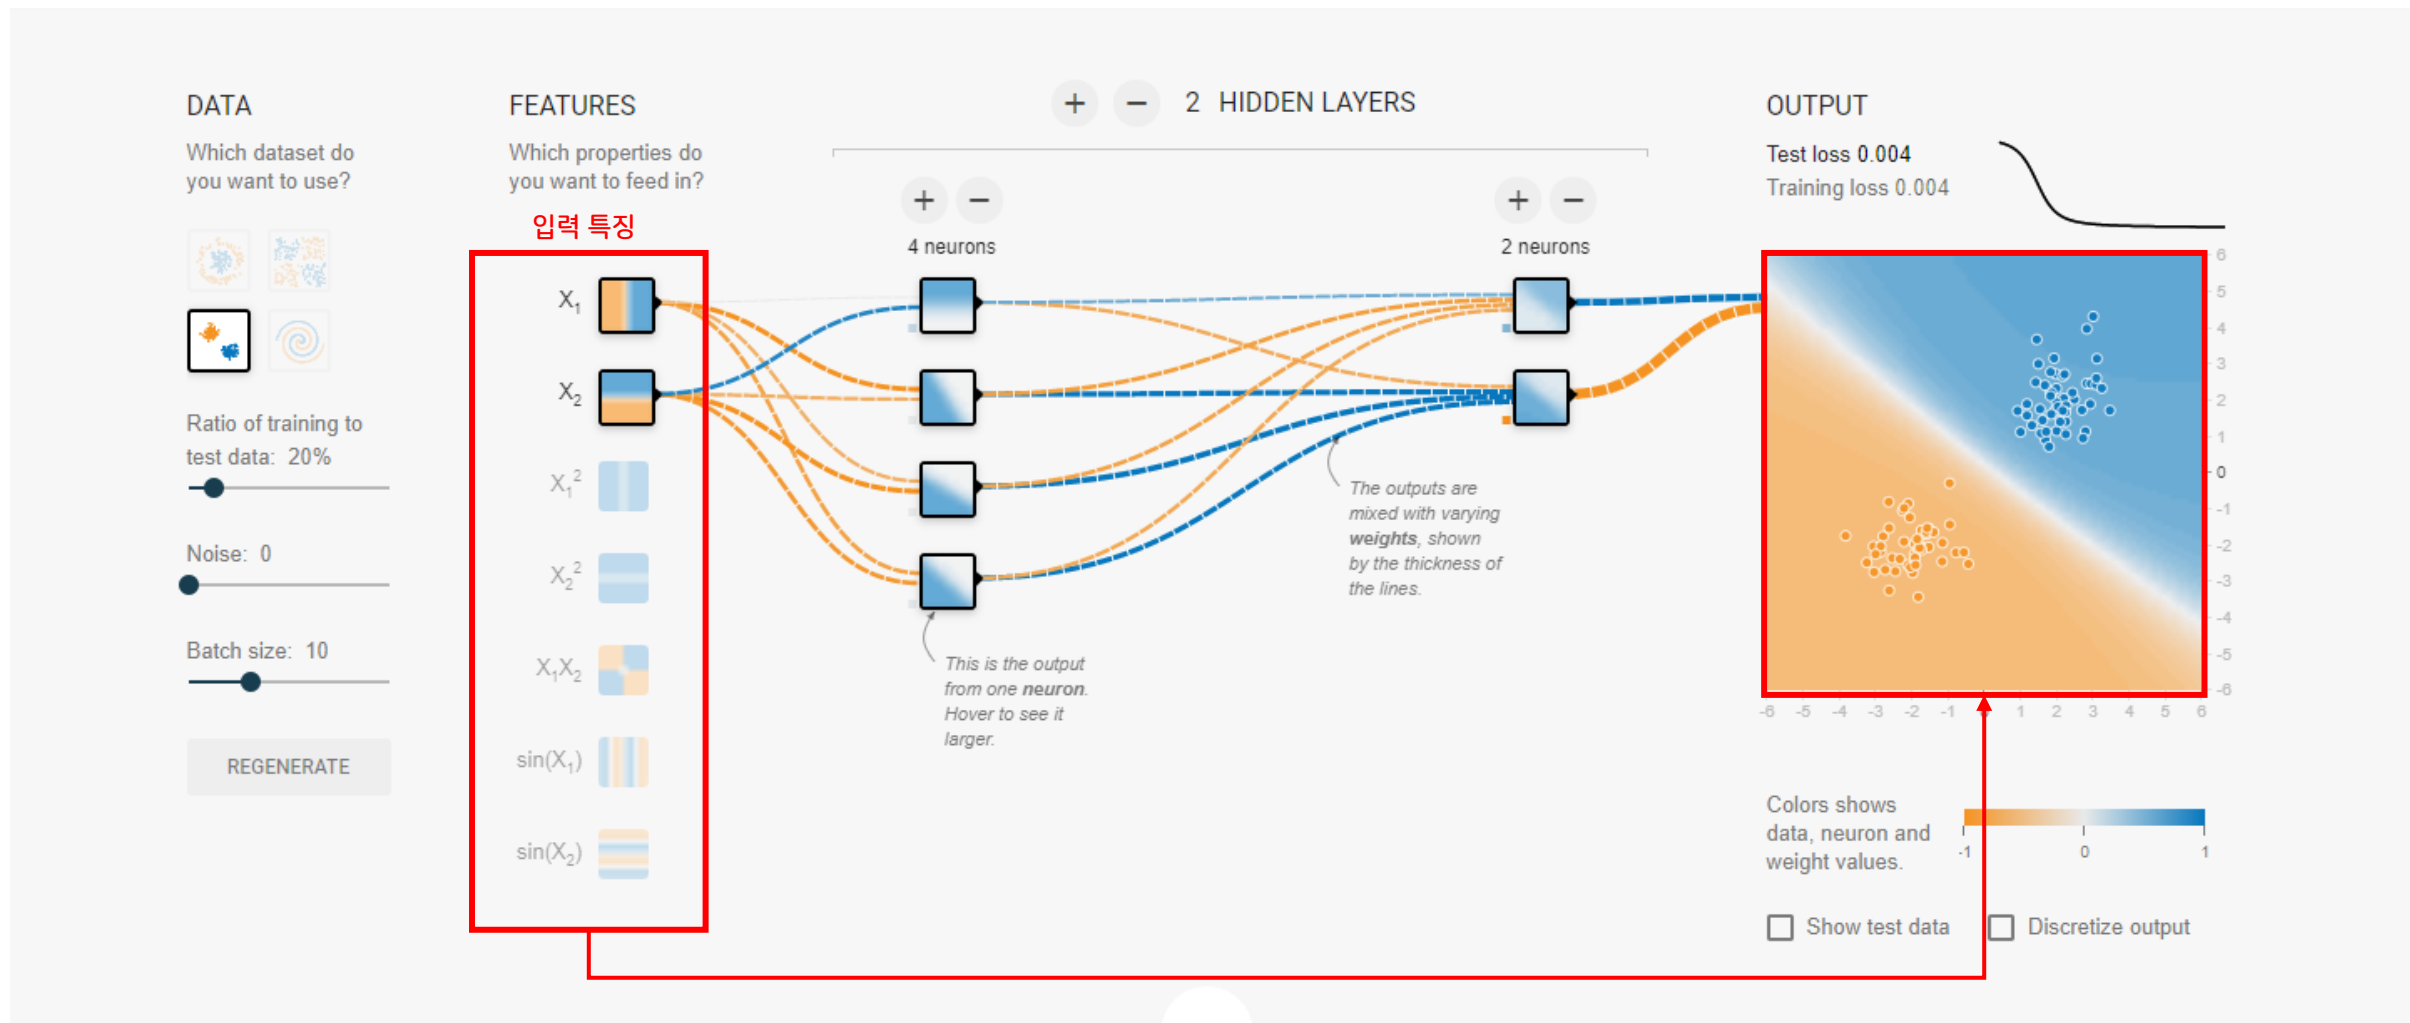
학습 데이터 비율



학습데이터 비율

전체 데이터 중 몇 %를 학습데이터로 사용할 것인지 결정

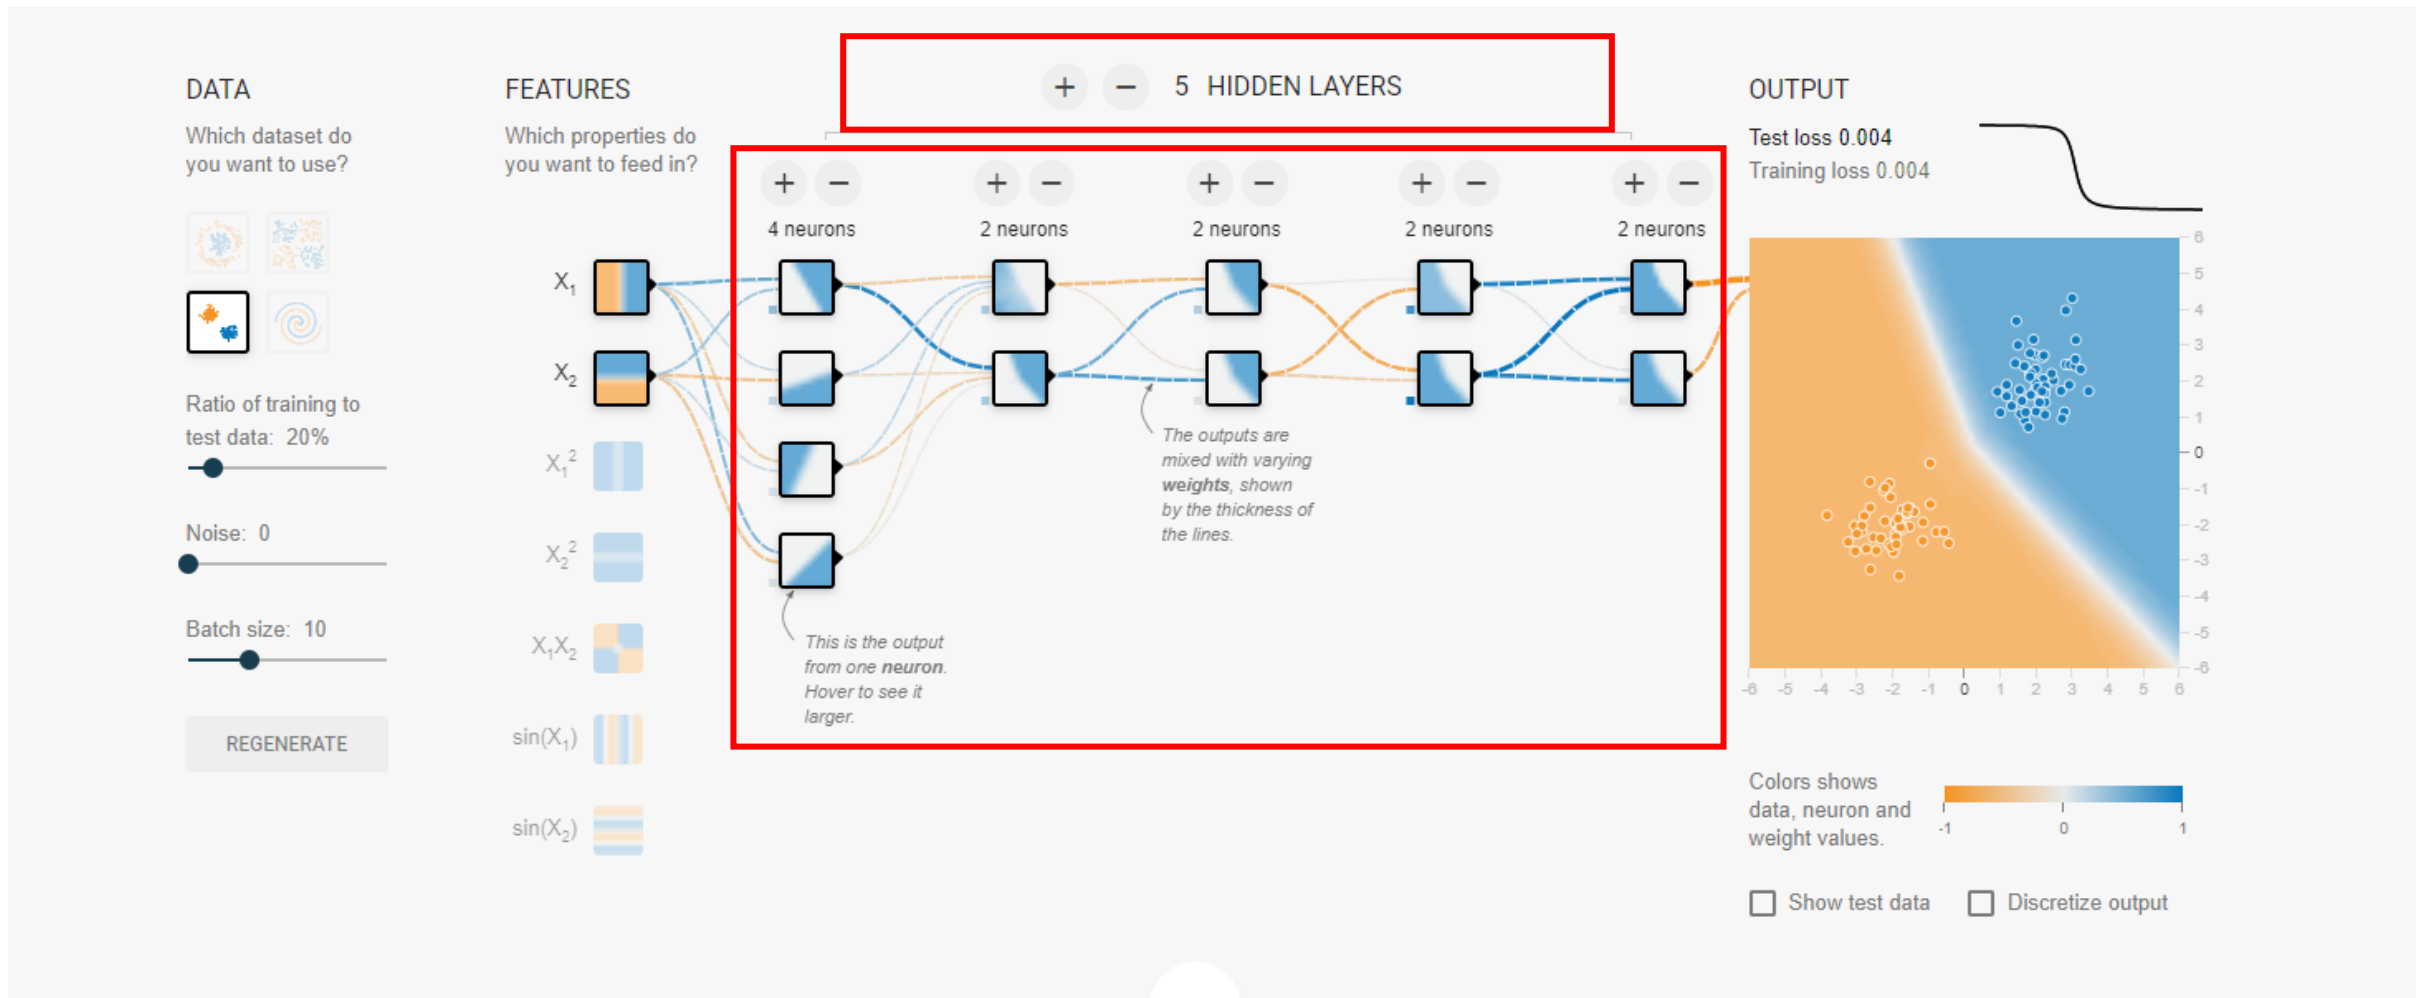
비율을 낮추면 점의 개수가 적어짐



입력 특징

x_1 : 데이터 세트에 있는 점들의 x 좌표, x_2 : 데이터 세트에 있는 점들의 y 좌표

입력 특징을 달리하여 출력 모양을 다르게 할 수 있음



은닉층 추가

은닉층을 추가하면 훨씬 더 부드러운 판단 경계선을 가짐

은닉층이 없으면 학습이 제대로 완료되지 않음



Epoch
000,147

Learning rate
0.03

Activation
Tanh


Regularization
None

Regularization rate
0

Problem type
Classification

DATA

Which dataset do you want to use?



Ratio of training to test data: 20%



Noise: 0



Batch size: 10



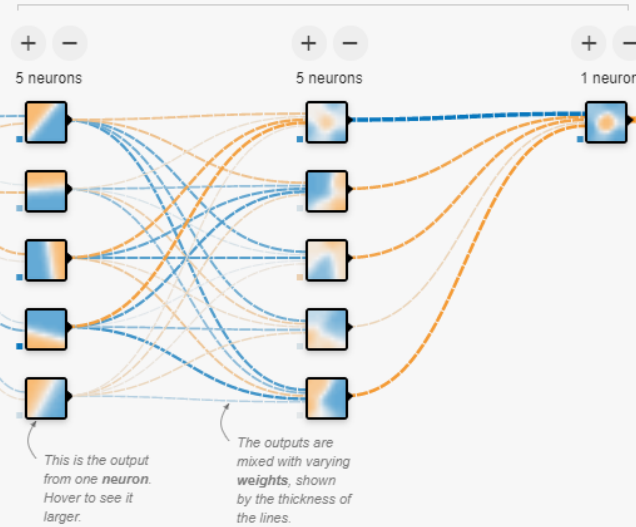
REGENERATE

FEATURES

Which properties do you want to feed in?


- ☒ X_1
- ☒ X_2
- ☐ X_1^2
- ☐ X_2^2
- ☐ X_1X_2
- ☐ $\sin(X_1)$
- ☐ $\sin(X_2)$

+ - 3 HIDDEN LAYERS




OUTPUT

Test loss 0.012
Training loss 0.005



Colors shows data, neuron and weight values.




☐ Show test data ☐ Discretize output

05

넘파이를 이용하여 MLP 구현

Numpy를 이용한 MLP



행렬을 사용하여 구현



```
import numpy as np

#시그모이드 함수
def actf(x):
    return 1/(1+np.exp(-x))

#시그모이드 함수의 미분값
def actf_deriv(x):
    return x*(1-x)

#XOR연산을 위한 4행 * 2열의 입력 행렬
#마지막 열은 바이어스를 나타냄
X = np.array([[0,0,1], [0,1,1], [1,0,1], [1,1,1]])

#XOR 연산을 위한 4행 * 1열의 목표 행렬
y = np.array([[0], [1], [1], [0]])

np.random.seed(5)

inputs = 3    #입력층의 노드 개수
hiddens = 6   #은닉층의 노드 개수
outputs = 1   #출력층의 노드 개수

#가중치를 -1.0에서 1.0 사이의 난수로 초기화한다
weight0 = 2*np.random.random((inputs,hiddens))-1
weight1 = 2*np.random.random((hiddens,outputs))-1
```

#반복

```
for i in range(10000):

    #순방향 계산
    layer0=X                                #입력을 layer0에 대입
    net1 = np.dot(layer0, weight0)          #행렬의 곱을 계산
    layer1 = actf(net1)                     #활성화 함수 적용
    layer1[:, -1]=1.0                       #마지막 열은 바이어스를 나타냄. 1.0으로 만든다

    net2 = np.dot(layer1, weight1)          #행렬의 곱을 계산
    layer2 = actf(net2)                     #활성화 함수 적용

    #출력층에서의 오차를 계산
    layer2_error = layer2-y

    #출력층에서의 델타값을 계산
    layer2_delta = layer2_error*actf_deriv(layer2)

    #은닉층에서 오차 계산
    #여기서 T는 행렬의 전치를 의미
    #역방향으로 오차를 전파할 때는 반대방향이므로 행렬이 전치되어야 함
    layer1_error=np.dot(layer2_delta,weight1.T)

    #은닉층에서의 델타를 계산
    layer1_delta=layer1_error*actf_deriv(layer1)

    #은닉층->출력층을 연결하는 가중치를 수정
    weight1 += -0.2*np.dot(layer1.T, layer2_delta)

    #입력층->은닉층을 연결하는 가중치를 수정
    weight0 += -0.2*np.dot(layer0.T, layer1_delta)

    print(layer2)
```

```
[[0.02449929]
 [0.98003059]
 [0.98066189]
 [0.02151195]]
```


06

구글의 텐서플로우

텐서플로우(TensorFlow)

딥러닝 프레임워크의 일종


텐서플로우 위에서 고수준 API를 제공하는Keras 라이브러리를 사용하여 구현

Tensor : 다차원 배열을 나타내는 용어로 스칼라, 벡터, 행렬, 텐서 지원

Flow : 데이터플로우를 의미

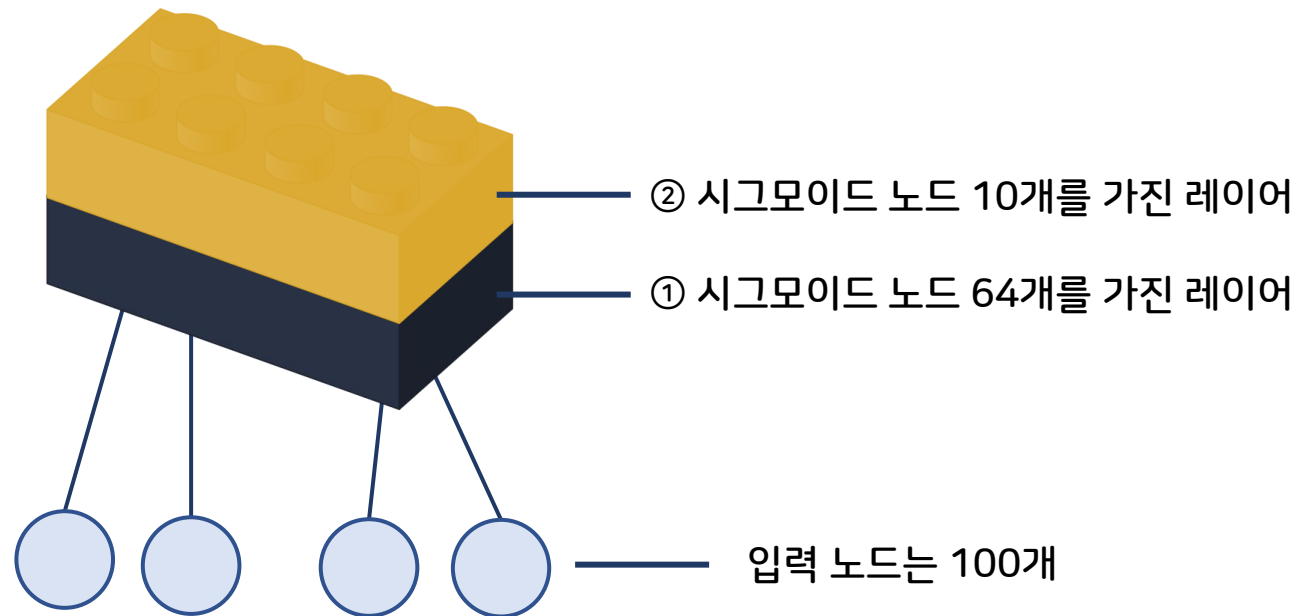
* Anaconda Navigator Version 5.2 에 TensorFlow, Keras 설치 필요

선형 스택 모델 생성



```
from tf.keras.models import Sequential  
  
model = Sequential()
```

Keras 라이브러리



```
from tf.keras.models import Sequential
```

```
model = Sequential() #선형 스택 모델 생성
```

```
①model.add(Dense(units=64, activation='sigmoid', input_dim=100)) #모델에 레이어 쌓기, 활성화함수 sigmoid, 입력개수 100개
```

```
②model.add(Dense(units=10, activation='sigmoid')) #노드의 개수 10개인 완전 연결된 레이어 추가
```

Keras 라이브러리

```
from tf.keras.models import Sequential

model = Sequential() #선형 스택 모델 생성

model.add(Dense(units=64, activation='sigmoid', input_dim=100)) #모델에 레이어 쌓기, 활성화함수 sigmoid, 입력개수 100개
model.add(Dense(units=10, activation='sigmoid')) #노드의 개수 10개인 완전 연결된 레이어 추가

#모델이 완성되면 compile()함수를 이용하여 학습과정을 구성/ loss='mse'는 손실함수 평균제곱오차, SGD는 확률적 경사하강법
model.compile(loss='mse', optimizer=sgd, metrics=['accuracy'])

#필요시 optimizer 세부 조정 가능 / 학습률: 0.01 / 모멘텀 : 0.9
#Model.compile(loss='mse', optimizer=keras.optimizers.SGD(lr=0.01, momentum=0.9))

#모델이 만들어지면 학습 진행. 학습은 fit() 함수호출
model.fit(X, y, epochs=5, batch_size=32)

#모델의 성능은 evaluate()함수로 평가
loss_and_metrics=model.evaluate(X, y, batch_size=128)

#새 데이터에 대한 예측은 predict()로 테스트 가능
classes = model.predict(new_X, batch_size=128)
```

Keras 예제 #1

```
import tensorflow as tf
import numpy as np
import matplotlib.pyplot as plt
```

#가상적인 데이터 생성


```
X = data = np.linspace(1,2,200) # 시작값=1, 종로값=2, 개수=200
y = X*4 + np.random.randn(200)*0.3 #x를 4배로 하고 편차 0.3정도의 가우시안 잡음 추가
```

```
model = tf.keras.models.Sequential() #선형 스택 모델 생성
model.add(tf.keras.layers.Dense(1, input_dim = 1, activation= ' linear ' )) #선형함수 사용
```

```
model.compile(optimizer= ' sgd ' , loss= ' mse ' , metrics=[ ' mse ' ]) #확률적 경사하강법, 손실함수는 평균제곱오차, 에포크는 30
model.fit(X,y,batch_size=1, epochs=30) #학습 진행
```

```
predict = model.predict(data) #새 데이터 예측
```

```
plt.plot(data,predict, ' b ' , data, y, ' k.') # 첫 번째 그래프는 파란색 마커로
plt.show() # 두 번째 그래프는 검정색 점으로
```



Keras 예제 #2

```
import tensorflow as tf
import numpy as np

X = np.array([[0,1],[0,1],[1,0],[1,1]]) #XOR연산을 위한 입력 행렬
y = np.array([[0],[1],[1],[0]]) #XOR연산을 위한 목표 행렬

model = tf.keras.models.Sequential() #선형 스택 모델 생성
model.add(tf.keras.layers.Dense(2, input_dim=2, activation='sigmoid')) #모델에 레이어 쌓기, 활성화함수는 sigmoid
model.add(tf.keras.layers.Dense(1, activation='sigmoid')) #모델에 레이어 쌓기, 활성화 함수는 sigmoid

sgd = tf.keras.optimizers.SGD(lr=0.1) #확률적 경사 하강법 학습률 0.1로 설정
model.compile(loss= ' mean_squared_error ', optimizer=sgd) #학습 과정 구성, 손실함수는 평균 제곱 오차

model.fit(X,y, batch_size=1, epochs=1000) #학습진행 에포크는 1000
print(model.predict(X)) #실행 출력
```

```
4/4 [=====] - 0s 748us/step - loss: 0.1487
Epoch 998/1000
4/4 [=====] - 0s 748us/step - loss: 0.1485
Epoch 999/1000
4/4 [=====] - 0s 998us/step - loss: 0.1484
Epoch 1000/1000
4/4 [=====] - 0s 748us/step - loss: 0.1484
[[0.4557345 ]
 [0.4557345 ]
 [0.8708291 ]
 [0.21653537]]
```

THANK YOU