

인공지능

CHAP 15 - 신경망4 (CNN)



Contents

신경망4 (CNN)

● 영상 인식이란?

● 전통적인 영상 인식 시스템의 구조

● 컨볼루션 신경망 (CNN)

● 풀링 또는 서브 샘플링

● DNN을 이용한 영상 분류

● CNN을 이용한 영상 분류



01

영상 인식이란?



영상 인식

영상 안의 물체를 인식하거나 분류하는 것

CHAP 15에서는 컨볼루션 신경망(CNN)을 이용한 영상 인식 방법을 학습



영상 분류기



- 고양이 : 83%
- 강아지 : 10%
- 모피 : 5%
- ...

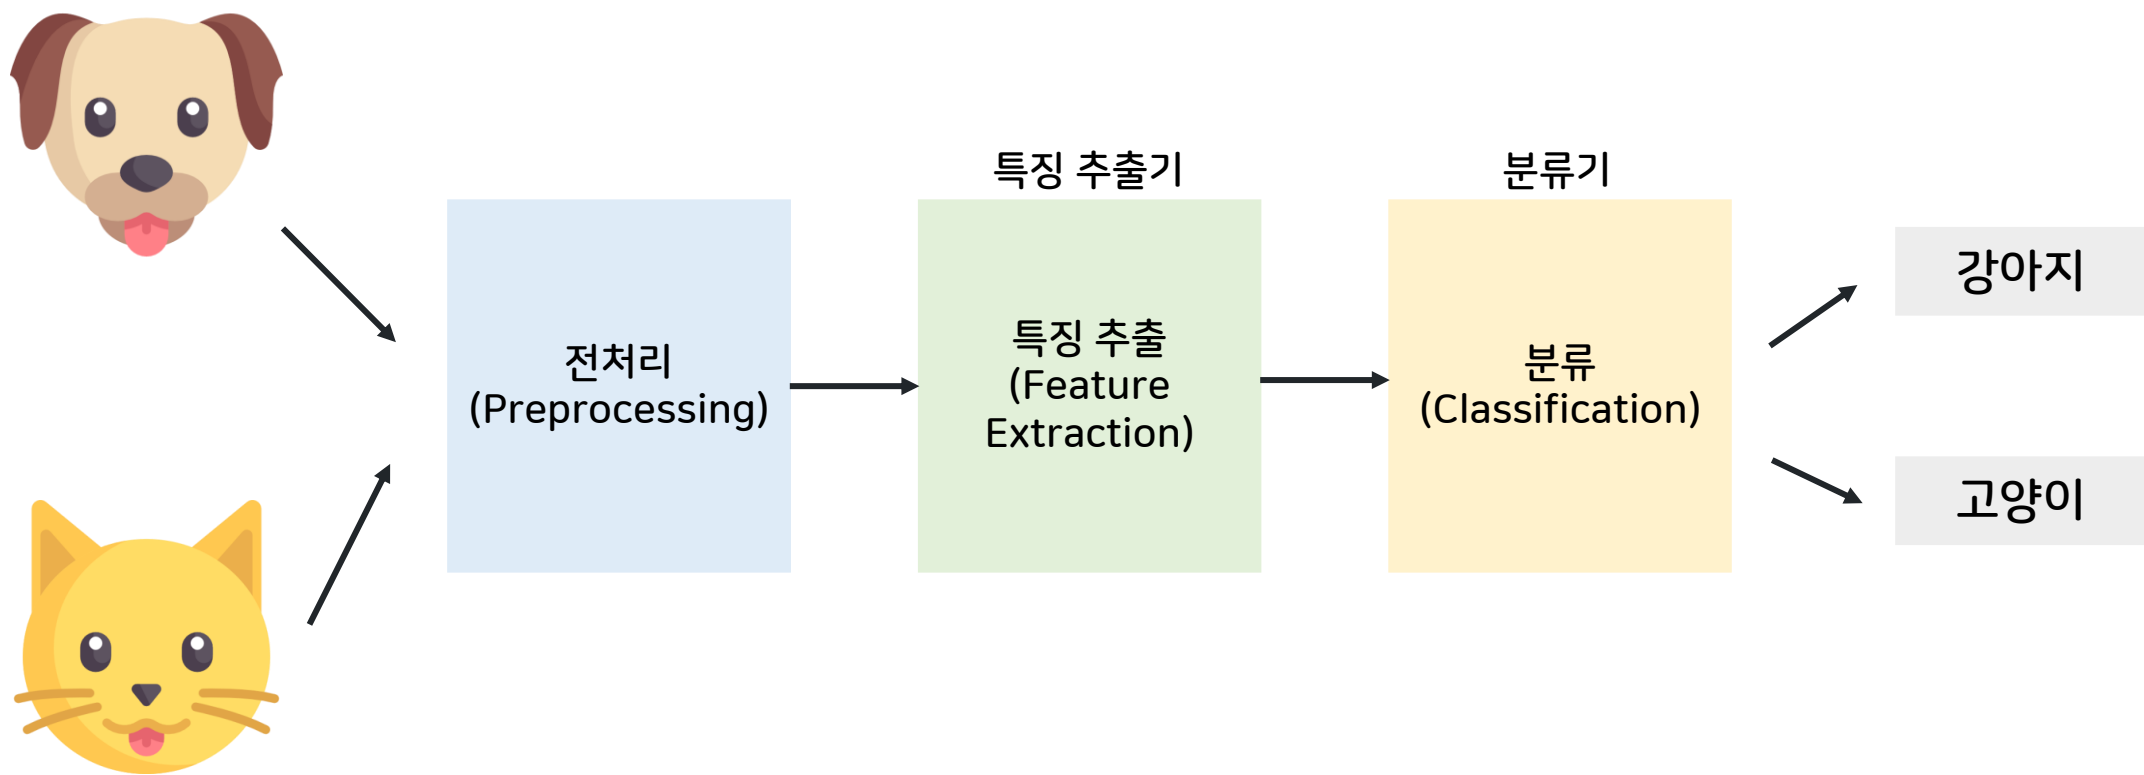


02

전통적인 영상 인식 시스템의 구조



전통적인 영상 인식 시스템의 구조




카메라가 동물의 영상을 캡처 → 잡음 제거 동물을 배경에서 분리 → 동물들의 특징 값 추출 → 특징 값들이 분류기로 보내짐 → 최종판단




전통적인 영상 인식 시스템의 구조

[키를 특징으로 사용]



상대적으로 겹치는 부분이 많아 분류 신뢰성 ↓

[밝기를 특징으로 사용]




특징을 한가지 더해도 겹치는 부분이 존재

강아지와 고양이를 더 잘 구분할 수 있는 방법은?



전통적인 영상 인식 시스템의 구조

[키와 밝기를 특징으로 사용]



$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$


특징 추출기는 입력 영상을 다음과 같은 특징 벡터(Feature Vector)로 변환

특징 벡터들이 존재하는 공간을 특징 공간(Feature Space)라고 함


특징 벡터가 판단경계선을 기준으로 오른쪽에 있으면 고양이, 왼쪽에 있으면 강아지로 분류



전통적인 영상 인식 시스템의 구조



[과잉적합]



[단순성 ↑]

판단경계선은 학습에서 사용한 샘플은 완벽하게 분류하지만 새로운 샘플에 대해서는 좋지 않은 성능을 나타낼 수 도 있음
성능과 분류기의 단순성을 적절하게 조합한 판단 경계선이 바람직할 수 도 있음



전통적인 영상 인식 시스템의 한계

이러한 방법의 문제점은 인간이 개입해야 한다는 점

특징을 선택하고 이미지에서 특징 값을 추출하는 과정은 인간이 해주어야 함

특징이 추출된 후에 분류하는 과정은 자동화가 가능

신경망을 연구하는 학자들은 특징의 선택과 추출도 학습을 연구



컨볼루션 신경망(Convolutional Neural Network :CNN)



03

컨볼루션 신경망(CNN)



컨볼루션 신경망(CNN : Convolution Neural Network)


동물의 시각세포에 영감을 받아 개발된 인공 신경망의 한 종류

DNN과는 달리 하위 계층의 노드들과 상위 계층의 노드들이 부분적으로만 연결되어 있음

영상 및 비디오 인식, 추천 시스템 및 자연어 처리 분야 등 폭넓게 사용



컨볼루션 신경망(CNN)의 기원



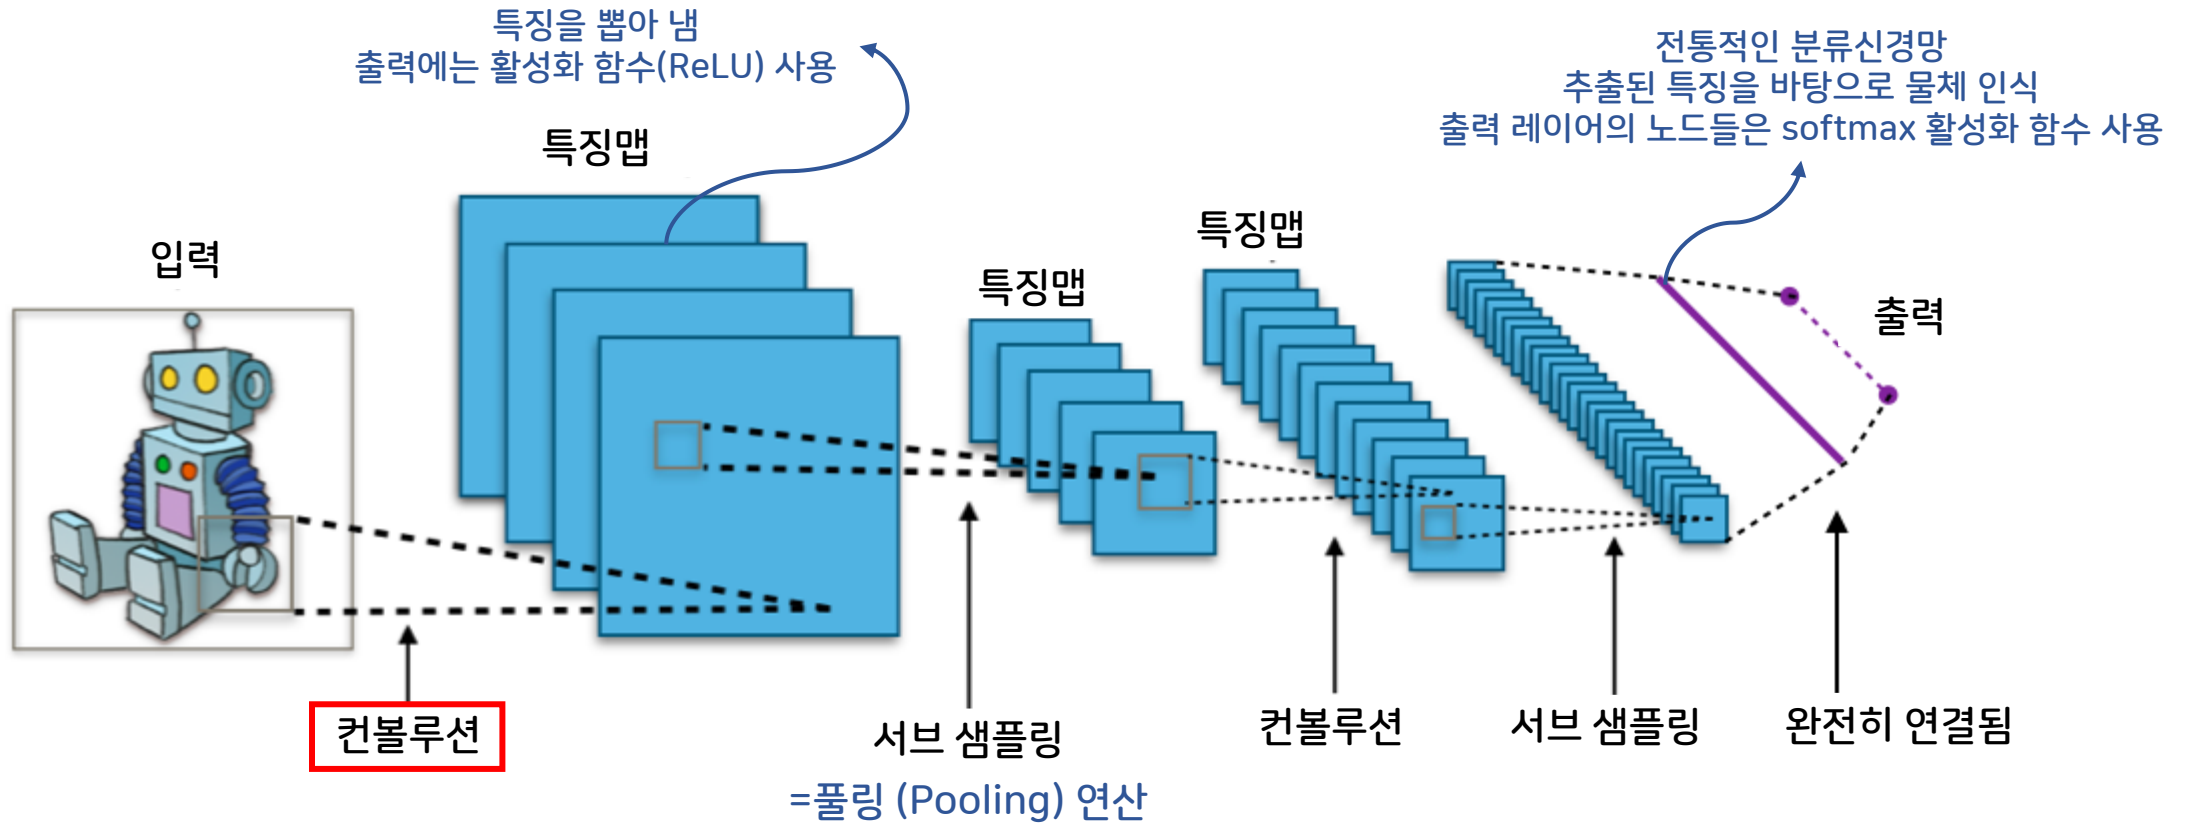
https://www.researchgate.net/figure/fig-In-the-classic-neuroscience-experiment-Hubel-and-Wiesel-discovered-a-cats-visual_fig1_335707980

<http://fourier.eng.hmc.edu/e180/lectures/v1/node7.html>

시야의 특정 부위가 자극을 받으면 신경 피질에 있는 특정 뉴런이 활성화 된다는 사실을 알아냄
이 뉴런을 수용장(Receptive Fields)이라고 부르며, 수용장에 있는 뉴런들은 **모두 부분적으로 겹치는 시야** 를 갖고 있다



컨볼루션 신경망(CNN)의 구조



컨볼루션이란?

영상 처리나 컴퓨터 시각에서는 가장 기본적인 연산
주변 화소값들에 가중치를 곱해서 더한 후에 이것을 새로운 화소값으로 하는 연산

1/9	1/9	1/9
1/9	1/9	1/9
1/9	1/9	1/9

가중치 마스크

3	6	6	4	7	8	2	1
3	4	3	8	8	3	3	2
5	7	7	7	7	4	3	2
8	9	9	9	9	9	3	2
8	3	3	4	3	2	1	1
8	9	9	8	8	3	3	2
6	4	3	8	8	3	3	2
7	4	3	8	8	3	3	2

입력 계층

$$\text{ReLU}(1/9 \times 3 + 1/9 \times 6 + 1/9 \times 6 + 1/9 \times 3 + 1/9 \times 4 + 1/9 \times 3 + 1/9 \times 5 + 1/9 \times 7 + 1/9 \times 7) = 4.88$$

	4.88						

출력 계층



컨볼루션이란?

1/9	1/9	1/9
1/9	1/9	1/9
1/9	1/9	1/9

가중치 마스크

3	6	6	4	7	8	2	1
3	4	3	8	8	3	3	2
5	7	7	7	7	4	3	2
8	9	9	9	9	9	3	2
8	3	3	4	3	2	1	1
8	9	9	8	8	3	3	2
6	4	3	8	8	3	3	2
7	4	3	8	8	3	3	2

입력 계층


$$\text{ReLU}(1/9 \times 6 + 1/9 \times 6 + 1/9 \times 4 + 1/9 \times 4 + 1/9 \times 3 + 1/9 \times 8 + 1/9 \times 7 + 1/9 \times 7 + 1/9 \times 7) = 5.77$$

	4.88	5.77					

출력 계층



컨볼루션이란?



필터의 가중치 학습

필터(마스크)가 여러 개 일 경우 동시에 여러 개의 출력이 나와 동시에 여러 개 필터의 가중치 학습이 가능함

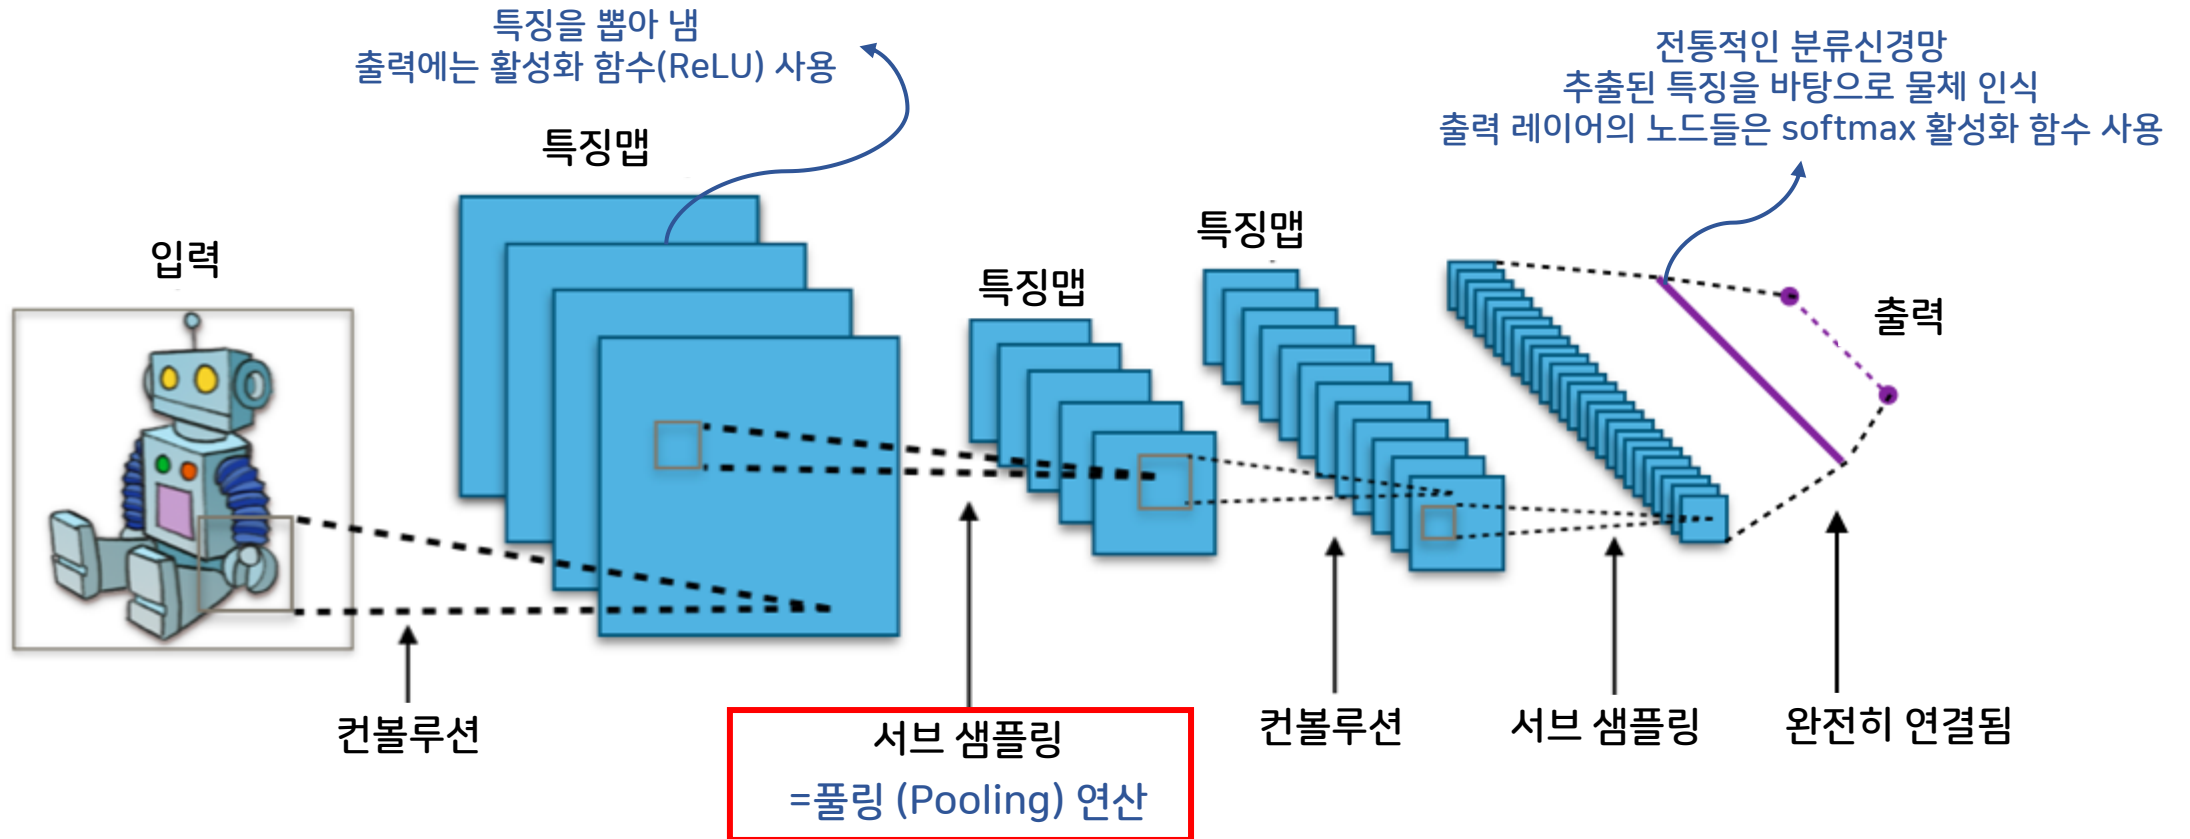


04

폴링 또는 서브 샘플링



컨볼루션 신경망(CNN)의 구조



풀링 or 서브 샘플링

입력 데이터의 크기를 줄이는 것 (입력 데이터의 깊이는 건드리지 않음)

Feature Map

6	4	8	5
5	4	5	8
3	6	7	7
7	9	7	2


Max-Pooling

<https://shafeentejani.github.io/2016-12-20/convolutional-neural-nets/>

- 계층의 크기가 작아지므로 계산이 빨라진다
- 계층의 크기가 작아진다는 것은 신경망의 매개변수가 작아진다는 것을 의미한다. 따라서 과적합이 나올 가능성이 줄어든다
- 공간에서 물체의 이동이 있어도 결과는 변하지 않는다. 즉 물체의 공간이동에 대하여 둔감해지게 된다.



공간이동에 대해 둔감해지다

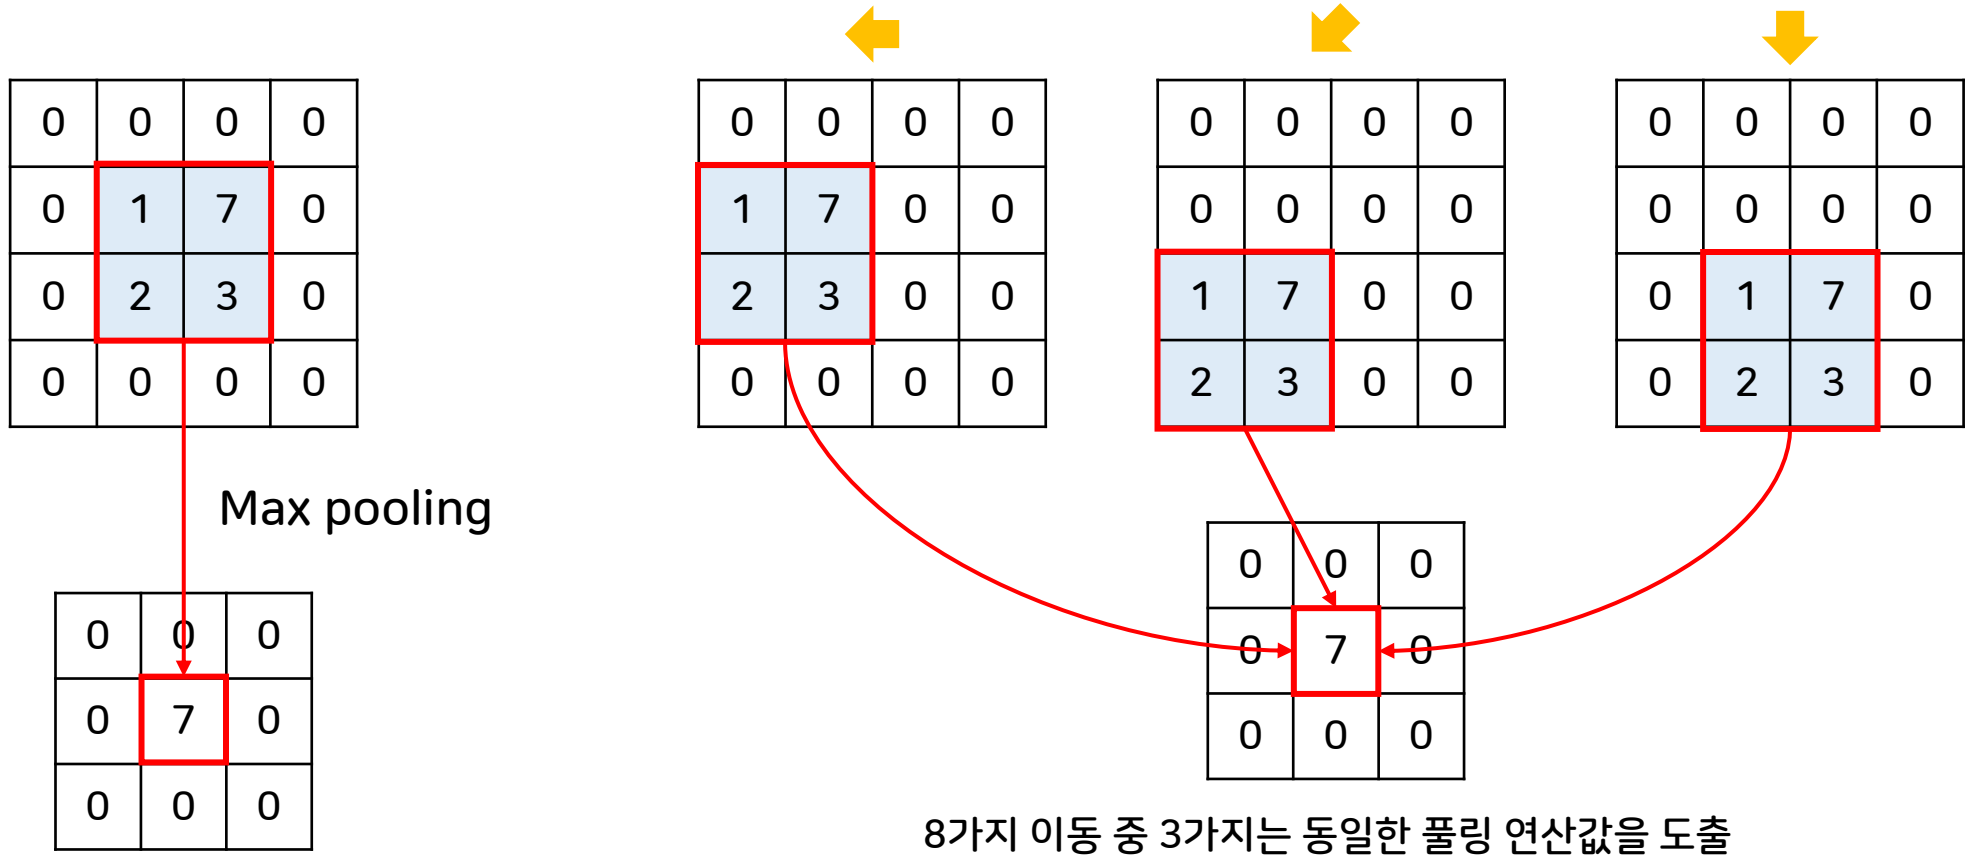


평행이동-불변(Translation-Invariant)

컴퓨터가 이미지 안에 있는 물체를 인식하기 위해서는 물체가 이동하더라도 동일하게 인식하여야 함



공간이동에 대해 둔감해지다



따라서 이미지에서 물체가 이동하여도 풀링 레이어의 값은 변하지 않을 가능성도 많음
 = 이미지에서 물체가 이동하여도 동일하게 인식함



05

DNN을 이용한 영상분류





Keras에서 제공하는 패션 MNIST 데이터셋을 사용
70,000개의 이미지 중에서 60,000개는 훈련하는데 이용 나머지는 성능 테스트에 사용



DNN : 완전연결 신경망 이용

```
import tensorflow as tf
from tensorflow import keras
import numpy as np
import matplotlib.pyplot as plt
from tensorflow.keras import datasets, layers, models
```

```
#MNIST에 있는 fashion_image 불러오기
fashion_mnist=keras.datasets.fashion_mnist
```

```
#4개의 넘파이 배열 얻기, 앞에 두개는 훈련용 데이터셋, 뒤에 두개는 테스트용 데이터셋
(train_images, train_labels), (test_images, test_labels) =
fashion_mnist.load_data()
```

```
#입력 데이터를 화면에 이미지로 출력
plt.imshow(train_images[0])
```

```
train_images = train_images/255.0 #이미지 화소값 실수로 만들어주기 (정규화)
test_images = test_images/255.0
```

```
model = models.Sequential()
```

```
#28x28크기의 2차원 배열을 784크기의 1차원 배열로 변환
model.add(layers.Flatten(input_shape=(28,28)))
```

```
#128개의 노드로 fully-connected된 계층, 활성화 함수는 ReLU
model.add(layers.Dense(128,activation='relu'))
```

```
#10개의 노드를 가지는 출력계층, 활성화함수는 softmax, 현재 이미지가 10개 범주 중 하나
에 속할 확률 출력
model.add(layers.Dense(10,activation='softmax'))
```

```
#학습 방법 : 적응적 학습
```

```
#손실함수:다중분류 손실함수
```

```
#성능측정 지표 : 신경망이 올바르게 분류하는 이미지의 비율(정확도)
```

```
model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])
```

```
#학습 실행
```

```
model.fit(train_images, train_labels, epochs=5)
```


```
#테스트 실행
```

```
test_loss, test_acc = model.evaluate(test_images, test_labels)
print('정확도 : ',test_acc)
```



DNN : 완전연결 신경망 이용 실행화면

Epoch 1/5
1875/1875 [=====] - 2s 847us/step - loss: 0.5009 - accuracy: 0.8238
Epoch 2/5
1875/1875 [=====] - 2s 858us/step - loss: 0.3754 - accuracy: 0.8633
Epoch 3/5
1875/1875 [=====] - 1s 800us/step - loss: 0.3357 - accuracy: 0.8780
Epoch 4/5
1875/1875 [=====] - 2s 804us/step - loss: 0.3113 - accuracy: 0.8863
Epoch 5/5
1875/1875 [=====] - 2s 810us/step - loss: 0.2944 - accuracy: 0.8917
313/313 [=====] - 0s 807us/step - loss: 0.3667 - accuracy: 0.8702
정확도 : 0.870199978351593



← 입력데이터



05

CNN을 이용한 영상분류



CNN : 컨볼루션 신경망 이용

```
import tensorflow as tf
from tensorflow import keras
import numpy as np
import matplotlib.pyplot as plt
from tensorflow.keras import datasets, layers, models
```

```
fashion_mnist = keras.datasets.fashion_mnist
```

```
#4개의 넘파이 배열 얻기, 앞에 두개는 훈련용 데이터셋, 뒤에 두개는 테스트용 데이터셋
(train_images, train_labels), (test_images, test_labels) =
fashion_mnist.load_data()
```

```
#훈련 이미지로 사용할 6만장의 이미지를 28x28x1크기의 3차원 배열로 변환
train_images = train_images.reshape((60000,28,28,1))
```

```
#테스트 이미지로 사용할 1만장의 이미지를 28x28x1크기의 3차원 배열로 변환
test_images = test_images.reshape((10000,28,28,1))
```

```
train_images = train_images / 255.0 #정규화
test_images = test_images / 255.0
```

```
model=models.Sequential() #스택모델 생성
```

```
#컨볼루션층
model.add(layers.Conv2D(32,(3,3), activation='relu',input_shape=(28,28,1)))
model.add(layers.MaxPooling2D((2,2))) #서브 샘플링(풀링)
```

```
model.add(layers.Conv2D(64,(3,3), activation='relu')) #컨볼루션층
model.add(layers.MaxPooling2D((2,2)))# 서브샘플링(풀링)
```

```
model.add(layers.Conv2D(64,(3,3),activation='relu'))#컨볼루션층
model.add(layers.Flatten())#3차원 배열을 1차원으로 변환
```

```
#노드 64개의 fully-connected 신경망, 활성화 함수 : ReLU
model.add(layers.Dense(64,activation='relu'))
```

```
#노드 10개의 출력층, 활성화 함수 : softmax
model.add(layers.Dense(10,activation='softmax'))
```

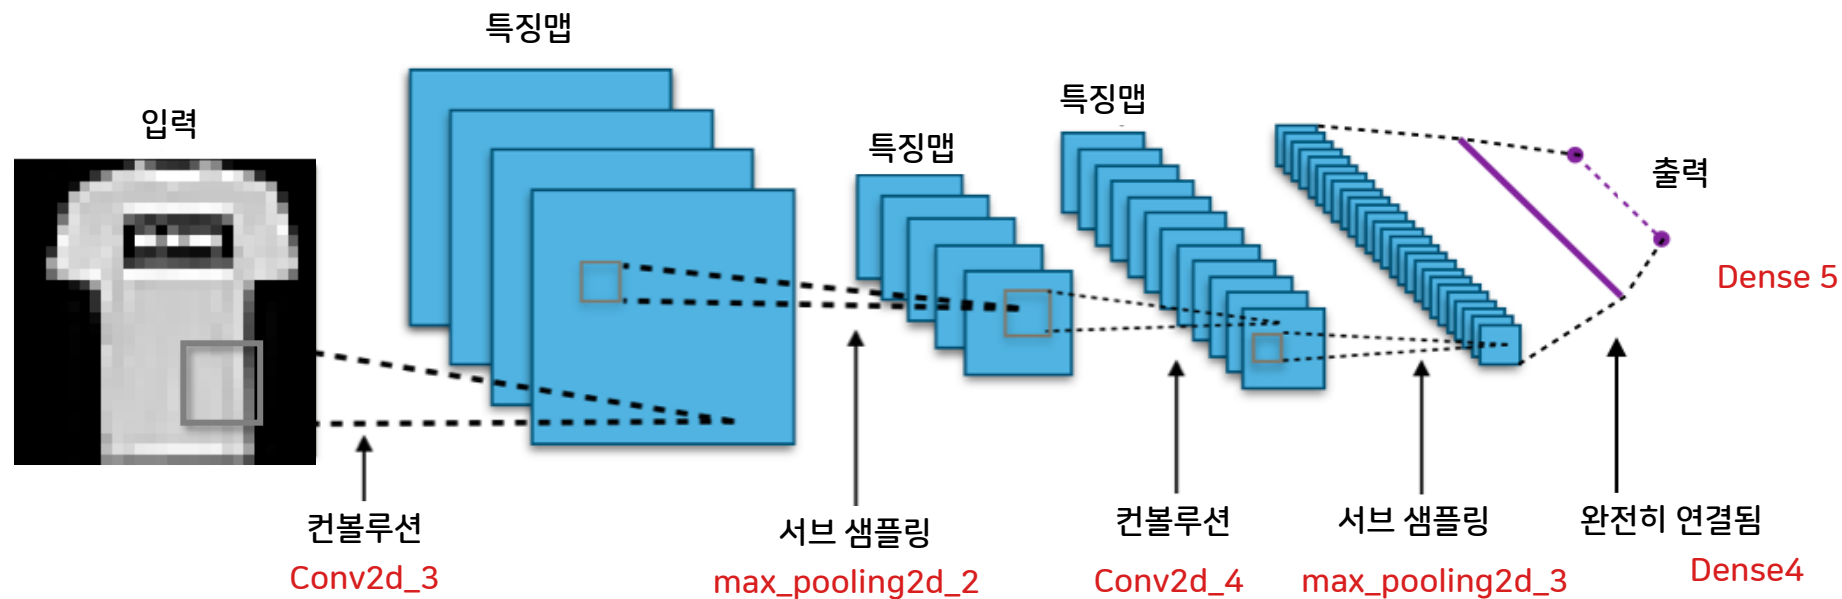
```
#model.summary() #모든 층 출력
```

```
#학습 방법 : 점진적 학습
#손실함수:다중분류 손실함수
#성능측정 지표 : 신경망이 올바르게 분류하는 이미지의 비율(정확도)
model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])
model.fit(train_images, train_labels, epochs=5)
```

```
test_loss, test_acc = model.evaluate(test_images, test_labels)
print('정확도 :', test_acc)
```



CNN : 컨볼루션 신경망 이용



Epoch 1/5
1875/1875 [=====] - 23s 12ms/step - loss: 0.4873 - accuracy: 0.8215
Epoch 2/5
1875/1875 [=====] - 21s 11ms/step - loss: 0.3210 - accuracy: 0.8833
Epoch 3/5
1875/1875 [=====] - 21s 11ms/step - loss: 0.2781 - accuracy: 0.8982
Epoch 4/5
1875/1875 [=====] - 21s 11ms/step - loss: 0.2470 - accuracy: 0.9083
Epoch 5/5
1875/1875 [=====] - 21s 11ms/step - loss: 0.2226 - accuracy: 0.9176
313/313 [=====] - 1s 3ms/step - loss: 0.2899 - accuracy: 0.8945

정확도 : 0.8945000171661377



THANK YOU

